

深度神经网络在信用卡欺诈检测中的应用研究

——基于树归纳偏置迁移的深度表格模型研究

2026 年 6 月 10 日

摘要

信用卡欺诈检测是金融风控领域最具挑战性的问题之一，其类别高度不平衡的特性对机器学习方法提出了严峻考验。本文基于 Kaggle 2023 年信用卡欺诈检测数据集（56.8 万条交易记录，经类别不平衡处理后使用约 15 万条样本），比较了两种异构深度神经网络架构（FT-Transformer、DeepFM）与 XGBoost 传统基线在欺诈检测任务上的表现，并提出了一种基于树归纳偏置迁移的知识蒸馏优化方案——将 XGBoost 的轴对齐分裂先验通过软标签蒸馏和特征重要性正则化迁移至深度模型。实验结果表明，DeepFM（AUPRC=0.9336）达到与 XGBoost（0.9331）统计上不可区分的性能水平；FT-Transformer 经 Sparsemax 替代 Softmax 后 AUPRC 达 0.9179，且获得最低业务成本（Cost=99）。Tree-Supervised 蒸馏消融实验揭示了一个关键的因果区分：软标签蒸馏（3A）对两种异构架构具有同等正向增益——FTT+KD 达 AUPRC=0.9347（+1.68pp）、DeepFM+KD 达 0.9495（+1.59pp），两者校准均近乎完美（ECE<0.001）；然而，特征重要性正则化（TreeReg, 3B）将 FTT 从 0.9347 断崖式拖降至 0.8974（-3.73pp），揭示树先验对嵌入层的刚性约束与 Sparsemax 注意力的自由交互学习存在结构性拮抗。本文还结合 SHAP 分析、注意力可视化和商业成本矩阵，从可解释性和业务成本两个维度为模型选择提供实证依据。

关键词：信用卡欺诈检测；深度神经网络；FT-Transformer；DeepFM；知识蒸馏；树归纳偏置；模型可解释性

摘要

Credit card fraud detection remains one of the most challenging problems in financial risk management, where extreme class imbalance poses significant difficulties for standard classification approaches. This paper compares two heterogeneous deep neural network architectures (FT-Transformer and DeepFM) against the XGBoost baseline, and proposes a tree-supervised knowledge distillation method that transfers XGBoost's axis-aligned inductive bias to deep models via soft-label distillation and feature-importance regularization. Experiments use the Kaggle 2023 Credit Card Fraud Detection dataset comprising 568,000 transactions (approximately 150,000 after inducing realistic class imbalance). Results show that DeepFM (AUPRC=0.9336) achieves statistically indistinguishable performance from XGBoost (0.9331); FT-Transformer with Sparsemax achieves AUPRC=0.9179 after a +4.4pp improvement over Softmax. A critical ablation reveals that soft-label distillation (3A) benefits both architectures equally —FTT+KD reaches AUPRC=0.9347 (+1.68pp), DeepFM+KD reaches 0.9495 (+1.59pp) —while feature-importance regularization (TreeReg, 3B) causes a catastrophic -3.73pp drop on FTT, exposing a structural antagonism between tree-derived embedding constraints and self-attention. Combined with SHAP analysis, attention visualization, and business cost matrices, this paper provides empirical evidence for model selection from both interpretability and cost perspectives.

Keywords: Credit Card Fraud Detection; Deep Neural Networks; FT-Transformer; DeepFM; Knowledge Distillation; Tree Inductive Bias; Model Interpretability

1 引言

1.1 研究背景

随着数字支付的普及，信用卡欺诈已成为全球金融体系面临的最严峻威胁之一。根据 Nilsson Report 的最新数据，2023 年全球信用卡欺诈损失预计超过 350 亿美元，且呈逐年增长趋势。传统的基于规则的风控系统在面对日益复杂的欺诈手段时显得力不从心——攻击者不断调整策略以规避固定规则，导致误报率居高不下，大量合法交易被误拦截，严重影响用户体验。

近年来，机器学习方法在欺诈检测领域展现出显著优势。相较于规则系统，机器学习模型能够自动从历史交易数据中学习欺诈模式，适应新型攻击手段。然而，欺诈检测面临一个根本性挑战：类别极端不平衡。在真实场景中，欺诈交易通常仅占总交易的 0.1% 至 1%，这使得标准分类模型倾向于将所有交易预测为“正常”，从而导致欺诈漏检。

深度神经网络在计算机视觉和自然语言处理领域的成功引发了其在表格数据上的探索热潮。传统观点认为，梯度提升树（如 XGBoost）在表格数据上的表现优于深度学习方法。但最新研究表明，专门为表格数据设计的深度架构——如 FT-Transformer 和 DeepFM——在特定场景下能够接近甚至超越树模型。然而，深度模型在表格数据上的核心瓶颈并非模型容量，而是归纳偏置的错配：树模型的轴对齐分裂天然契合表格特征的异构性，而深度模型的全连接层和全局注意力缺乏这一先验。

1.2 研究问题

本文旨在回答以下核心研究问题：

- 深度表格模型（FT-Transformer、DeepFM）在信用卡欺诈检测任务上的表现是否能接近或超越 XGBoost 基线？自注意力机制和显式特征交互两种不同的归纳偏置在 PCA 匿名化特征空间中表现如何？
- 能否通过知识蒸馏将 XGBoost 的树归纳偏置（软标签分布 + 特征分裂重要性）迁移至深度模型，从而缩小深度模型与树模型之间的性能差距？
- 深度模型的注意力机制能否为欺诈检测提供有价值的可解释性？
- 在考虑实际业务成本的情况下，何种模型具有最佳的精度-成本权衡？

1.3 本文贡献

本文的主要贡献如下：

- 统一评估框架下的异构架构横向比较：**在同一数据集和统一评估框架下，比较了两种异构深度表格架构（FT-Transformer 的全局自注意力 vs. DeepFM 的显式特征交互）与 XGBoost 基线的性能，揭示了不同归纳偏置在 PCA 匿名化特征空间中的表现差异；
- 树归纳偏置迁移方法：**提出了 Tree-Supervised 知识蒸馏方案，将 XGBoost 的软标签分布（方案 3A）和特征分裂重要性先验（方案 3B）迁移至 FT-Transformer，验证了树模型的轴对齐归纳偏置可通过蒸馏增强深度模型的表格数据处理能力；

3. **多维可解释性分析**: 结合 SHAP 全局特征归因、个体瀑布图和 FT-Transformer 注意力权重, 从多个视角解读模型决策逻辑, 并诊断了自注意力在 PCA 空间中的均匀塌缩问题;
4. **成本敏感评估**: 引入业务成本矩阵 ($C_{FP} = 1, C_{FN} = 10$), 揭示 AUPRC 最优与业务成本最优之间的非单调关系, 为实际部署提供帕累托前沿分析。

1.4 论文结构

本文的其余部分组织如下: 第二节回顾相关工作; 第三节描述方法论; 第四节呈现实验结果; 第五节进行多维分析 (可解释性、校准、成本); 第六节讨论商业启示、局限性和未来工作; 第七节总结全文。

2 相关工作

2.1 传统信用卡欺诈检测方法

信用卡欺诈检测的早期工作主要依赖基于规则的风控引擎和传统统计方法。逻辑回归 (Logistic Regression) 因其简单性和可解释性被广泛使用, 但其线性假设限制了捕捉复杂欺诈模式的能力。决策树和随机森林 (Random Forest) 通过集成多棵决策树提升了泛化能力, 并能处理非线性关系。Bhattacharyya 等人 [bhattacharyya2011data](#) 比较了支持向量机 (SVM)、随机森林和逻辑回归在欺诈检测上的表现, 发现随机森林在精确率-召回率权衡上表现最佳。

2.2 梯度提升方法

梯度提升树 (Gradient Boosting Decision Trees) 已成为表格数据上的标杆方法。XGBoost [chen2016xgboost](#) 通过引入正则化项和列采样防止过拟合, 在多个 Kaggle 欺诈检测竞赛中占据主导地位。LightGBM 和 CatBoost 进一步优化了训练效率和类别特征处理。然而, 这些模型在处理极高维稀疏特征和复杂特征交互时仍存在局限, 且缺乏对特征重要性的细粒度解释。

2.3 深度表格模型

近年来, 研究者开始探索将深度学习应用于表格数据的有效方法。Borisov 等人 [borisov2024deep](#) 在其综述中系统性地梳理了表格深度学习的两大技术路线: 基于 Transformer 的架构 (如 FT-Transformer、SAINT) 和基于显式特征交互的架构 (如 DeepFM、DCN-V2), 并指出表格数据对深度学习的独特挑战——异构特征、缺失值、不规则分布以及缺乏旋转不变性等归纳偏置。以下概述与本论文直接相关的代表性工作。

FT-Transformer [gorishniy2021revisiting](#) 将 Transformer 架构适配到表格数据。核心思想是将每个数值特征通过 Feature Tokenizer 映射为嵌入向量, 在所有特征令牌前添加一个可学习的 CLS 令牌, 然后通过标准 Transformer 编码器进行自注意力计算。CLS 令牌的最终表示用于分类。FT-Transformer 在多个表格数据基准上取得了有竞争力的结果, 但在中等规模数据上树模型仍可能保持优势 [grinsztajn2022tree](#)。

DeepFM [guo2017deepfm](#) 结合了因子分解机 (Factorization Machine) 和深度神经网络。FM 组件通过嵌入向量的内积高效捕获二阶特征交互, Deep 组件通过多层感知机学习高阶特征表示。两者共享特征嵌入层, 实现端到端联合训练。DeepFM 最初用于点击率预测, 但其特征交互建模能力同样适用于欺诈检测。

SAINT [somepalli2022saint](#) 在 FT-Transformer 的基础上引入了两种注意力机制的混合——对特征令牌间的自注意力 (列注意力) 和对样本间的行注意力——并通过自监督对比预

训练提升了小样本场景下的性能。SAINT 的结构设计表明，注意力机制的双重应用是表格深度学习的重要方向。

2.4 后 FT-Transformer 时代：2022–2025 年进展

尽管 FT-Transformer 在多个基准上取得了优异表现,Grinsztajn 等人`grinsztajn2022tree`在 45 个表格数据集上的大规模实证研究发现了一个重要反例：在中等规模数据（<10 万样本）上，基于树的模型（尤其是 XGBoost 和随机森林）即使不经过超参数调优，仍然持续优于深度模型。该研究指出，树模型的轴对齐分裂策略天然契合表格数据缺乏旋转不变性的特点，而神经网络对无信息特征（随机噪声列）更为敏感，性能下降幅度显著更大。这一发现对深度表格模型的研究方向产生了深远影响。

TabPFN`hollmann2023tabpfn`提出了范式性的突破：通过在数百万合成数据集上预训练一个 Transformer，使其学会贝叶斯推理过程，从而能在 0.1 秒内对新的小规模表格分类问题（ ≤ 1000 样本、 ≤ 100 特征）做出预测，且无需任何训练。但 TabPFN 目前受限于输入维度和小样本规模，尚无法直接应用于信用卡欺诈检测这类大规模场景。

Dastidar 等人`dastidar2024survey`在信用卡欺诈检测领域对机器学习和深度学习方法进行了系统综述，发现深度模型（尤其是 LSTM 和自编码器）在高维特征建模和序列行为检测方面具有独特优势，但在实际部署中仍面临数据隐私、类别不平衡和概念漂移等核心挑战。该综述进一步强调了 AUPRC 而非 ROC-AUC 作为主要评估指标的合理性，以及将可解释性分析纳入模型开发流程的必要性。

综上所述,本文的研究定位如下:在 15 万 + 样本的信用卡欺诈数据集上,以 FT-Transformer (全局自注意力) 和 DeepFM (显式特征交互) 代表两种不同的归纳偏置,系统比较深度表格模型与传统梯度提升方法在 AUPRC 和商业成本指标上的表现。在此基础上,本文引入 Tree-Supervised 知识蒸馏方案,将 XGBoost 的树结构先验迁移至深度模型,探索”以树为师”的归纳偏置增强路径。同时,通过 SHAP 分析和注意力可视化,为不平衡学习和可解释性提供实证证据。

2.5 类别不平衡处理

针对类别不平衡问题，现有方法可分为三大类：（1）数据层面方法，如随机过采样和 SMOTE`chawla2002smote`，通过生成少数类合成样本来平衡训练集；（2）算法层面方法，如类别加权和代价敏感学习，通过调整损失函数中不同类别的权重来关注少数类；（3）损失函数改进，如 Focal Loss`lin2017focal`，通过降低易分类样本的损失贡献，使模型聚焦于难分类样本。本文在实验部分对这三类方法进行了系统比较。

2.6 模型可解释性

在金融风控场景中，模型可解释性不仅是监管合规的要求，更是获取业务方信任的关键。SHAP`lundberg2017unified`基于 Shapley 值的博弈论框架，为每个特征分配对预测结果的贡献值，是目前最被广泛接受的可解释性方法之一。对于树模型，TreeExplainer 提供了快速精确的 SHAP 值计算。对于深度模型，FT-Transformer 的内置注意力机制提供了额外的可解释性维度——通过可视化 [CLS] Token 对各特征的注意力权重，可以直观理解模型在做出预测时关注了哪些特征。

3 方法论

3.1 符号定义

为保持全文符号一致性，本文采用以下统一符号体系：

表 1: 全文统一符号定义。包含数据集、特征向量、类别标签、模型预测函数、分类阈值、混淆矩阵元素和业务成本等核心符号。

符号	含义
$\mathcal{D}$	完整数据集 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$
$\mathbf{x}_i \in \mathbb{R}^d$	第 i 个样本的特征向量 ($d = 29$)
$y_i \in \{0, 1\}$	类别标签 (0= 正常交易, 1= 欺诈交易)
$\mathcal{D}_{\text{train}}, \mathcal{D}_{\text{val}}, \mathcal{D}_{\text{test}}$	训练集、验证集、测试集
N	样本总数
d	特征维度
$f(\cdot)$	模型预测函数, $f: \mathbb{R}^d \rightarrow [0, 1]$
$\hat{y}_i = f(\mathbf{x}_i)$	模型对样本 i 的预测概率
τ	分类阈值, $\hat{y}_i \geq \tau$ 判定为欺诈
TP, FP, FN, TN	真正例、假正例、假负例、真负例
Cost	业务成本, $\text{Cost} = C_{FP} \cdot \text{FP} + C_{FN} \cdot \text{FN}$
C_{FP}, C_{FN}	误报成本、漏报成本 ($C_{FP} = 1, C_{FN} = 10$)
ϕ_j	特征 j 的 Shapley 值

3.2 数据来源与探索性分析

本文采用 Kaggle 平台上的 Credit Card Fraud Detection Dataset 2023 数据集 **kaggle2023fraud**。该数据集包含信用卡交易记录，原始数据超过 56.8 万条，且正负类接近 1:1 平衡。然而，真实信用卡欺诈的比率通常仅为 0.1%–1%，为模拟这一现实场景，本文对多数类（正常交易）进行下采样并限制最大样本数为 150,000，同时从少数类（欺诈交易）中随机抽取 750 条，使最终欺诈比例约为 0.5%（正负比约 1:200）。数据已通过 PCA 进行部分匿名化处理，但其规模（处理后 150,750 条记录）为深度学习模型提供了充足的训练样本。

3.2.1 数据集特征

数据集共包含 31 个特征列：28 个匿名化 PCA 特征 (V1-V28)、交易金额 (Amount) 和类别标签 (Class, 0= 正常, 1= 欺诈)。初步探索性分析显示：

- 总交易数：150,750 (150,000 正常 + 750 欺诈)
- 欺诈交易占比：0.5% (严重不平衡, 正负比约 1:200)
- 无缺失值，所有特征均为数值型
- Amount 特征呈现典型的长尾分布
- 部分 V 特征在欺诈和正常交易间呈现显著分布差异

图1呈现了经不平衡处理后的完整数据集类别分布：正常交易样本数为 150,000，欺诈交易样本数仅为 750，正负类比例约为 200:1。这种极端的类别不平衡是信用卡欺诈检测任务的核心挑战——模型在训练过程中极易被多数类主导，导致对少数类的识别能力严重退化。仅 0.5% 的欺诈比例意味着，即使一个“将所有交易预测为正常”的朴素分类器也能达到 99.5%

的准确率——这正是准确率（Accuracy）在不平衡场景下完全失效的原因，也解释了本文为何采用 AUPRC 而非准确率作为主要评估指标。

图2以核密度估计对比了两类交易的金额分布。蓝色曲线（正常交易， $n = 150,000$ ）和橙色曲线（欺诈交易， $n = 750$ ）均呈现明显的右偏（长尾）分布，但存在两个关键差异：第一，欺诈交易的 KDE 峰值位置略高于正常交易，表明欺诈者倾向于选择中等偏高的交易金额以在”隐匿性”与”收益”之间取得平衡；第二，在高金额区间（ $> 15,000$ 标准化单位），欺诈交易的密度相对更高，这与银行业务经验一致——高价值交易是欺诈者的优先目标。然而，两类分布在整体上存在大量重叠区域，意味着仅凭交易金额远不足以区分欺诈与正常交易，必须依赖多维特征联合判别。




图 1: 经不平衡处理后的数据集类别分布。正常交易 150,000 条，欺诈交易 750 条，正负比约 200:1，准确率在此场景下完全失效。




图 2: 正常交易与欺诈交易的金额核密度估计曲线。蓝色为正常交易，橙色为欺诈交易，两类均呈右偏分布且存在大量重叠，欺诈交易在高金额区间密度略高。

上述 EDA 结果表明，任何有效的欺诈检测模型必须：（1）采用针对性的不平衡处理策略（如 Focal Loss、SMOTE 或类别加权），因为 0.5% 的欺诈率使标准分类器失效；（2）依赖多维特征联合判别而非单一金额阈值，因为两类金额分布存在大量重叠；（3）在评估时优先使用

对类别不平衡敏感的指标（如 AUPRC 而非 ROC-AUC 或准确率）。

3.3 数据预处理

数据预处理流水线包含以下步骤：

1. **特征选择**：移除 ID 列（不携带预测信息）。
2. **异常值处理**：对 Amount 特征采用 IQR 方法进行异常值截断（仅在训练集上计算上下界，避免数据泄露）。V1-V28 为 PCA 变换后的特征，其分布为原始特征的线性组合，不具有传统意义上的“异常值”含义，因此不做截断处理。
3. **标准化**：使用 StandardScaler 对所有数值特征进行标准化（拟合于训练集，应用于验证集和测试集）。
4. **数据集划分**：按 70%/15%/15% 进行分层划分（Stratified Split），确保各个子集中欺诈比例一致。

3.4 模型架构

本文实现并比较了两种异构深度神经网络架构与 XGBoost 传统基线。在此基础上，引入 Tree-Supervised 知识蒸馏方案（第三节），将 XGBoost 的树归纳偏置迁移至 FT-Transformer：

3.4.1 XGBoost 基线

XGBoost (eXtreme Gradient Boosting) [chen2016xgboost](#) 作为传统表格数据的强基线，采用梯度提升树框架。本文使用 300 轮提升、最大深度 8、学习率 0.05，并通过 `scale_pos_weight` 参数根据训练集正负比自动调节类别权重。为充分利用数据，XGBoost 在训练集和验证集的合并数据上训练。

3.5 FT-Transformer：特征令牌化与自注意力机制

FT-Transformer (Feature Tokenizer + Transformer) 由 Gorishniy 等人 [gorishniy2021revisiting](#) 于 2021 年提出，其核心思想是将表格数据的每个数值特征视为一个独立的“词元” (Token)，通过 Transformer 编码器的自注意力机制学习特征间的全局交互。以下从四个层面逐层拆解其工作原理。

3.5.1 整体架构

FT-Transformer 将表格分类问题转化为类似 NLP 的序列分类问题：每条数据记录被表示为一个特征令牌序列，模型通过在所有特征上计算成对注意力来捕获特征间关系。图3以流程图呈现了从原始特征到最终预测的完整数据流。

3.5.2 第一层：Feature Tokenizer——为什么数值需要“嵌入”

传统做法将表格数据的一行直接输入 MLP ($\mathbb{R}^{29} \rightarrow \text{Linear}(29, 64)$)，这等价于对所有特征使用同一个投影矩阵。FT-Transformer 的关键创新在于为每个特征 j 分配独立的可学习参数 $\mathbf{W}_j$ 和 $\mathbf{b}_j$ ：

$$T_j = x_j \cdot \mathbf{W}_j + \mathbf{b}_j \in \mathbb{R}^{d_{model}} \quad (1)$$




图 3: FT-Transformer 架构流程图。29 个数值特征经 Feature Tokenizer 映射为 64 维嵌入向量，前置可学习的 [CLS] Token 后送入 3 层 Transformer 编码器。[CLS] 的最终输出经 LayerNorm 和线性层得到欺诈概率。右侧虚线框展示编码器内部两大核心组件。

其中 $\mathbf{W}_j$ 的作用不是线性变换（因为 x_j 是标量），而是**特征专属的嵌入向量**——将标量特征值沿特定方向”拉伸”为 d_{model} 维向量。理解这一设计的关键在于：

- **异构特征需要异构空间**：V14（强判别性 PCA 成分）和 V25（近噪声成分）的变化量 Δx 对最终决策的影响截然不同。若所有特征共享同一投影矩阵，模型将无法区分”重要的 0.1”和”不重要的 0.1”。Feature Tokenizer 使每个特征拥有独立的”语义通道”，其嵌入向量的方向编码了该特征的身份（identity），模长编码了其数值强度。
- **为注意力提供可区分的 Key/Query**：自注意力通过 Query-Key 内积 $\langle \mathbf{Q}_i, \mathbf{K}_j \rangle$ 度量特征 i 对特征 j 的”关注程度”。若特征嵌入是同一线性变换的产物，则所有特征将位于同一低维子空间，Query-Key 内积丧失区分度——这正是本文在 PCA 匿名化数据上观察到的”注意力均匀塌缩”的根本原因。

在本文的实验中， $d_{\text{model}} = 64$ 意味着每个标量特征被映射为一个 64 维向量，29 个特征共计产生 $29 \times (64 + 64) = 3,712$ 个专属参数。

3.5.3 第二层：[CLS] Token——从序列到分类的桥梁

借鉴 BERT `devlin2018bert` 的设计，FT-Transformer 在所有特征令牌前添加一个可学习的 [CLS] Token $T_{\text{CLS}} \in \mathbb{R}^{d_{\text{model}}}$ ，形成长度为 30 的序列：

$$\mathbf{Z}_0 = [T_{\text{CLS}}, T_1, T_2, \dots, T_{29}] \in \mathbb{R}^{30 \times 64} \quad (2)$$

[CLS] Token 的设计哲学是**信息汇聚**：它自身不携带任何特征信息（随机初始化），但在经过多层自注意力后，它通过 Query 机制从所有特征令牌中”抽取”了对分类最有用的信息。可以理解为——[CLS] 是模型学会的”最佳问题”（optimal query），而每个特征令牌提供的是该特征的”回答”（key-value pair）。最终，仅 [CLS] 的输出被送入分类头，其余 29 个特征令牌的输出被丢弃。

3.5.4 第三层：Multi-Head Self-Attention——特征间的全局对话

这是 FT-Transformer 的核心计算引擎。给定输入序列 $\mathbf{Z} \in \mathbb{R}^{S \times d}$ ($S = 30$)，单头自注意力执行以下操作：

Step 1: 线性投影。将每个令牌分别投影为 Query、Key、Value 三个向量：

$$\mathbf{Q} = \mathbf{Z}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{Z}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{Z}\mathbf{W}_V \quad (3)$$

其中 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d \times d_k}$, $d_k = d_{\text{model}}/n_{\text{heads}} = 8$ 。

Step 2: Scaled Dot-Product Attention。计算每对令牌间的注意力分数：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Sparsemax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (4)$$

除以 $\sqrt{d_k}$ 的目的是防止内积过大导致 Sparsemax/Softmax 饱和（梯度消失）。30 个令牌的注意力矩阵为 $\mathbb{R}^{30 \times 30}$ ——每个特征对其他 29 个特征（包括 [CLS] 和自身）分配一个注意力权重。

Step 3: Multi-Head 整合。并行执行 $n_{\text{heads}} = 8$ 个独立的注意力计算（每头使用不同的 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ ），将各头输出拼接后线性投影：

$$\text{MultiHead}(\mathbf{Z}) = \text{Concat}(\text{head}_1, \dots, \text{head}_8) \mathbf{W}_O \quad (5)$$

多头设计使模型能在不同的表示子空间中同时关注不同类型的关系——例如，一个头可能聚焦于 V14-V12 的相关性，另一个头关注 V4-V17 的交互。然而，本文的实验发现：在 PCA 匿名化特征上，各头输出的注意力分布高度相似，表明 PCA 破坏了供多头分化的语义多样性。

Step 4: Transformer Encoder Block。每个编码器层包含两个子层，每子层均有残差连接和 LayerNorm：

$$\begin{aligned} \mathbf{Z}' &= \text{LayerNorm}(\mathbf{Z} + \text{MultiHead}(\mathbf{Z})) \\ \mathbf{Z}'' &= \text{LayerNorm}(\mathbf{Z}' + \text{FFN}(\mathbf{Z}')) \end{aligned} \quad (6)$$

其中 FFN 为两层 MLP： $\text{FFN}(\mathbf{x}) = \text{GELU}(\mathbf{x}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2$ ，中间维度 $d_{\text{ffn}} = 256$ 提供 4 倍于 d_{model} 的容量以进行非线性变换。残差连接确保即使注意力学不到有用信息（如均匀塌缩），梯度仍能通过恒等路径回传，避免深层网络的退化。

3.5.5 第四层：Sparsemax——本文的关键改进

原始 FT-Transformer 使用 Softmax 归一化注意力权重：

$$\text{Softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_j e^{z_j}} \quad (7)$$

Softmax 存在两个固有问题：（1）它永远输出全非零的概率分布（ $e^{z_i} > 0$ 恒成立），无法产生真正的稀疏解；（2）当所有 z_i 接近时（如在 PCA 空间中），输出趋于均匀分布 $1/d$ 。

本文采用 Sparsemax **martins2016sparsemax** 替代 Softmax。Sparsemax 将 logits 向量 $\mathbf{z}$ 投影到概率单纯形（probability simplex）上，产生**可能包含零值**的稀疏概率分布：

$$\text{Sparsemax}(\mathbf{z}) = \arg \min_{\mathbf{p} \in \Delta^{d-1}} \|\mathbf{p} - \mathbf{z}\|_2^2 \quad (8)$$

其闭式解为 $\text{Sparsemax}(\mathbf{z})_i = \max(z_i - \tau(\mathbf{z}), 0)$ ，其中 $\tau(\mathbf{z})$ 是确保 $\sum_i \max(z_i - \tau, 0) = 1$

的唯一阈值。算法复杂度为 $O(d \log d)$ ，不增加计算负担。

核心差异：Softmax 对低 logits 值赋予微量但非零的概率（如 0.001），Sparsemax 直接将其设为零。在表格数据语境中，这意味着特征 j 完全可以被排除在特征 i 的“注意力视野”之外——模型被强制做出选择。本实验证实，Sparsemax 将 FT-Transformer 的 AUPRC 从 0.8738 提升至 0.9179 (+4.4pp)，ECE 从 0.2328 降至 0.0120（改善约 20 倍）。

需要指出，本文未分离 Sparsemax 的稀疏化效应与其隐式的温度/熵调节效应——Sparsemax 的投影操作（ ℓ_2 范数最小化至单纯形）在降低输出熵的同时引入稀疏性，两者可能独立贡献于 AUPRC 和 ECE 的改善。Softmax+ 温度缩放（temperature scaling）可能以不同机制实现类似的熵调节效果，这一替代路径留待未来验证。

3.5.6 本文配置与训练细节

- $d_{model} = 64, n_{heads} = 8, n_{layers} = 3, d_{ffn} = 256$
- 总参数量：153,921（合理范围，避免过拟合 15 万训练样本）
- 优化器：AdamW（lr= 5×10^{-4} , weight_decay= 10^{-4} ）
- 损失函数：Focal Loss（ $\alpha = 0.25, \gamma = 2.0$ ）—— $\alpha = 0.25$ 被选为 Sparsemax 的搭配，因稀疏注意力需要均衡的正负类梯度信号
- 早停：验证集 AUPRC 连续 15 轮不提升

3.6 DeepFM：显式特征交互与因子分解机

DeepFM 由 Guo 等人 [guo2017deepfm](#) 于 2017 年提出，最初应用于点击率（CTR）预测。其核心思想是将因子分解机（Factorization Machine, FM）的显式二阶特征交互与深度神经网络的高阶表示学习融合于一个端到端框架中。与 FT-Transformer 的“隐式”交互（通过注意力权重间接建模）不同，DeepFM 采用“显式”交互——直接计算每对特征的向量内积。

3.6.1 整体架构

DeepFM 由三个组件构成，共享底层的特征嵌入层。图4展示了从前向传播到最终预测的完整数据流。

3.6.2 第一层：共享嵌入

每个特征 x_i （标量）被映射为一个 K 维嵌入向量（本文 $K = 16$ ）：

$$\mathbf{e}_i = x_i \cdot \mathbf{v}_i \in \mathbb{R}^K \quad (9)$$

其中 $\mathbf{v}_i \in \mathbb{R}^K$ 是特征 i 的专属嵌入向量。所有这些 $\mathbf{v}_i$ 在 FM 组件和 Deep 组件之间共享——这意味着 FM 学习到的成对关系会通过反向传播同时优化 Deep 路径使用的嵌入表示。共享机制是 DeepFM 超越“FM+MLP 串联”的关键：两个组件的训练信号在嵌入层交汇，FM 提供的结构化交互信号充当 Deep 路径的正则化先验。

3.6.3 第二层：FM 组件

FM 组件由两部分组成：

一阶部分（线性）：

$$y_{\text{linear}} = w_0 + \sum_{i=1}^D w_i x_i \quad (10)$$




图 4: DeepFM 架构流程图。29 个数值特征经共享嵌入层映射为 16 维向量，分两路并行计算：FM 路径执行显式一阶和二阶特征交互，Deep 路径通过三层 MLP 学习高阶表示。两路输出与全局偏置 w_0 求和后经 Sigmoid 输出。共享嵌入是 DeepFM 的核心设计——FM 的交互质量直接影响 Deep 路径的初始表示。

这部分等价于逻辑回归——每个特征有独立的线性权重 w_i ，直接对预测值做加减。 w_0 是全局偏置。

二阶部分（成对交互）：

$$y_{\text{FM}} = \sum_{i=1}^D \sum_{j=i+1}^D \langle \mathbf{v}_i, \mathbf{v}_j \rangle \cdot x_i x_j \quad (11)$$

这是 FM 的核心。对每一对特征 (i, j) ，其交互强度由两个因素共同决定：

1. **数值乘积** $x_i \cdot x_j$ ：如果两个特征同时偏高（如 V14 和 V12 均异常高），乘积大 $\rightarrow$ 交互贡献大。
2. **嵌入相似度** $\langle \mathbf{v}_i, \mathbf{v}_j \rangle$ ：两个特征的嵌入向量越“对齐”（内积越大），它们对预测的协同效应越强。

关键数学技巧—— $O(D^2K) \rightarrow O(DK)$ ：直接计算公式(11)需要对 $D(D-1)/2$ 对特征各计算一次 K 维内积，复杂度 $O(D^2K)$ 。通过以下代数变换可降至 $O(DK)$ ：

$$\begin{aligned} \sum_{i=1}^D \sum_{j=i+1}^D \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j &= \frac{1}{2} \left(\sum_{i=1}^D \sum_{j=1}^D \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j - \sum_{i=1}^D \langle \mathbf{v}_i, \mathbf{v}_i \rangle x_i^2 \right) \\ &= \frac{1}{2} \left(\sum_{f=1}^K \left(\sum_{i=1}^D v_{i,f} x_i \right)^2 - \sum_{i=1}^D \sum_{f=1}^K v_{i,f}^2 x_i^2 \right) \end{aligned} \quad (12)$$

式(12)的关键在于将双重求和 $\sum_i \sum_j$ 转化为先对 i 求和再平方的结构——这只需要 $O(DK)$ 次乘法和加法，而非 $O(D^2K)$ 次。当 $D = 29$ 时， $O(DK) = 464$ 次操作 vs. $O(D^2K) = 13,456$ 次操作，加速约 29 倍。这一变换使得 FM 的大规模特征交互在计算上可行。

3.6.4 第三层：Deep 组件

Deep 组件是一个标准的前馈神经网络，接收所有特征嵌入向量的拼接（flatten）作为输入：

$$\mathbf{h}_0 = \text{Concat}(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_{29}) \in \mathbb{R}^{D \times K=464} \quad (13)$$

随后通过三层全连接网络：

$$\begin{aligned} \mathbf{h}_1 &= \text{ReLU}(\mathbf{W}_1 \mathbf{h}_0 + \mathbf{b}_1), \quad \mathbf{W}_1 \in \mathbb{R}^{256 \times 464} \\ \mathbf{h}_2 &= \text{ReLU}(\mathbf{W}_2 \mathbf{h}_1 + \mathbf{b}_2), \quad \mathbf{W}_2 \in \mathbb{R}^{128 \times 256} \\ \mathbf{h}_3 &= \text{ReLU}(\mathbf{W}_3 \mathbf{h}_2 + \mathbf{b}_3), \quad \mathbf{W}_3 \in \mathbb{R}^{64 \times 128} \end{aligned} \quad (14)$$

每层后应用 Dropout ($p = 0.3$) 防止过拟合。Deep 组件可以学习任意阶的特征交互——例如，V14×V12×V4 的三阶交互可以通过两层 ReLU 的非线性组合隐式建模。

3.6.5 第四层：最终融合

三路输出求和后经 Sigmoid 得到最终预测：

$$\hat{y} = \sigma \left(\underbrace{w_0 + \sum_{i=1}^{29} w_i x_i}_{\text{一阶线性}} + \underbrace{\frac{1}{2} \sum_{f=1}^{16} \left[\left(\sum_i v_{i,f} x_i \right)^2 - \sum_i v_{i,f}^2 x_i^2 \right]}_{\text{FM 二阶交互}} + \underbrace{\mathbf{W}_{\text{out}} \cdot \mathbf{h}_3}_{\text{Deep 高阶}} \right) \quad (15)$$

为什么使用”求和”而非”拼接”融合？FM 和 Deep 组件共享嵌入层，它们的输出已经位于相关的语义空间。求和是一种参数无关的融合方式，允许模型通过反向传播自动分配两个组件的相对贡献——如果 FM 的二阶交互足够，Deep 输出趋近于零；如果高阶模式更关键，Deep 输出主导预测。

3.6.6 DeepFM 在 PCA 空间中的优势

本文的关键实验发现——DeepFM (AUPRC=0.9336) 优于 FT-Transformer (0.9179) ——可从架构设计中得到解释：

1. **不依赖特征”身份”的全局比较：**FT-Transformer 的注意力通过 Query-Key 内积评估”特征 i 对特征 j 有多重要”，这要求特征嵌入空间具有可区分的几何结构。PCA 匿名化抹去了特征的原始语义，使各嵌入向量在空间中高度同质化，内积趋同 → 注意力均匀。DeepFM 的 $\langle \mathbf{v}_i, \mathbf{v}_j \rangle$ 内积只是两个嵌入向量的”对齐程度”的静态度量，不依赖 Query-Key 的动态上下文——它在训练前就确定了”V14 和 V12 的交互值得关注”。
2. **交互的直接性：**FM 的二阶交互是 $x_i \cdot x_j \cdot \langle \mathbf{v}_i, \mathbf{v}_j \rangle$ 的简单三因子乘积，梯度路径短且稳定。FT-Transformer 的交互需要经过 Softmax/Sparsemax 归一化 + Value 加权求和 + 残差连接，梯度需要穿越多个非线性层。
3. **知识蒸馏的兼容性：**XGBoost 的分裂决策本质上是轴对齐的——每次分裂沿单一特征维度判断 $x_i > t$ 。DeepFM 的一阶线性项 $w_i x_i$ 直接对应这种轴对齐模式，软标签蒸馏的信号得以无损注入。而 FT-Transformer 的注意力无视特征轴，蒸馏信号在注意力矩阵中经过非线性变换后被稀释。

3.6.7 本文配置与训练细节

- $K = 16$ (嵌入维度)，Deep layers=[256, 128, 64]，Dropout=0.3
- 总参数量：161,648 (略高于 FT-Transformer 的 153,921)
- 优化器：AdamW (lr= 10^{-3} , weight_decay= 10^{-4})

- 损失函数：Focal Loss ($\alpha = 0.995$ 即类别反比, $\gamma = 2.0$) ——DeepFM 使用强类别加权以弥补其缺乏内置稀疏注意力 (Sparsemax) 的劣势
- 蒸馏配置 (DeepFM+KD): $T = 4.0, \alpha_{KD} = 0.7$ ——软标签权重占 30%, Focal Loss 占 70%

3.7 训练策略

3.7.1 Focal Loss

本文采用 Focal Loss 作为主要损失函数 **lin2017focal**:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (16)$$

其中 $p_t = p$ 当 $y = 1$ 否则 $p_t = 1 - p$, $\alpha_t = \alpha$ 当 $y = 1$ 否则 $\alpha_t = 1 - \alpha$ 。
两个关键超参数:

- γ (聚焦参数): 控制对易分类样本的”惩罚”力度。 $\gamma = 0$ 退化为标准交叉熵, γ 越大, 模型越关注难分类样本。
- α (平衡参数): 调节正负类之间的权重。对于 FT-Transformer, 因其 Sparsemax 注意力需要更均衡的梯度信号, 使用默认值 $\alpha = 0.25$; 对于 DeepFM, 设 $\alpha = 1 - \text{正类比例}$, 使少数类获得更高的损失权重。

本文将 Focal Loss 作为主要损失函数用于所有深度模型训练。

3.7.2 优化设置

所有神经网络模型使用 AdamW 优化器 ($\beta_1 = 0.9, \beta_2 = 0.999$), 配合 ReduceLROnPlateau 学习率调度 (当验证集 AUPRC 连续 8 轮无提升时, 学习率减半)。训练采用以下策略:

- 批量大小: 512
- 最大训练轮数: 100
- 早停策略: 验证集 AUPRC 连续 15 轮无提升时停止
- 梯度裁剪: $\text{max_norm}=1.0$
- 最佳模型保存: 基于验证集 AUPRC

3.8 评估指标

3.8.1 主要指标: AUPRC

鉴于类别高度不平衡, AUPRC (Area Under Precision-Recall Curve) 是比 ROC-AUC 更合适的评估指标 **saito2015precision**。ROC-AUC 在不平衡数据上可能给出过于乐观的评估, 因为真负类 (True Negative) 占主导地位。PR 曲线聚焦于正类 (欺诈) 的预测质量, 对样本分布变化更为敏感。

3.8.2 次要指标

- ROC-AUC: 便于与文献中的现有工作对比
- F1-Score: 在最佳阈值（基于验证集 F1 最大化）处计算
- Precision & Recall: 分别衡量误报率和漏报率

3.8.3 商业成本指标

从银行业务角度出发，误报（将正常交易标记为欺诈）和漏报（未检出欺诈交易）的成本截然不同：

$$\text{Cost} = FP \times C_{FP} + FN \times C_{FN}, \quad C_{FP} = 1, C_{FN} = 10 \quad (17)$$

漏报 (FN) 的真实成本大约是误报 (FP) 的 10 倍——未发现的欺诈交易导致直接资金损失，而误报仅需额外的人工审核。

4 实验

4.1 实验设置

所有实验在一台配备 Intel Core i7-13700 CPU 和 NVIDIA GeForce RTX 4060 (8GB) GPU 的计算机上进行，深度学习框架为 PyTorch 2.11.0+cu128。为保证可复现性，所有随机种子统一设置为 42，并在每个模型训练前显式重置所有随机状态 (random、numpy、torch、cuda)。FT-Transformer 和 DeepFM 因 rtdl 和 deepctr-torch 在当前环境下不适配，使用手写实现。

4.1.1 XGBoost 基线配置

XGBoost: 300 轮提升，最大深度 8，学习率 0.05，scale_pos_weight 根据训练集正负比自动计算。为充分利用数据，XGBoost 在训练集和验证集的合并数据上训练；深度模型仅使用训练集训练并通过验证集早停。

4.2 模型性能对比

表2汇总了三种模型在六项评估指标上的定量结果，所有指标均基于各自最优分类阈值（通过验证集 F1 最大化确定）计算得出。

表 2: 各模型的综合性能对比（按 AUPRC 降序排列）。DeepFM 以微弱优势 (0.9336) 超越 XGBoost (0.9331)，FT-Transformer 凭借 Sparsemax 达到 0.9179 且业务成本最低 (99)。

模型	AUPRC	ROC-AUC	F1	Precision	Recall	Cost	ECE
DeepFM	0.9336	0.9979	0.8938	0.8860	0.9018	123	0.0394
XGBoost	0.9331	0.9979	0.8750	0.9479	0.8125	215	0.0006
FT-Transformer	0.9179	0.9925	0.9196	0.9196	0.9196	99	0.0120

如表2所示：

(1) XGBoost 的显著优势。XGBoost 以 AUPRC=0.9331 位居榜首，验证了 Grinsztajn 等人 [grinsztajn2022tree](#) 的发现——基于树的集成方法在表格数据上仍具有归纳偏置优势。其高精确率 (0.9479) 使误报率极低，但召回率 (0.8125) 为三模型中最低，提示其在检出全部欺诈方面仍存提升空间。

(2) 异构架构对比：显式交互优于全局自注意力。两种深度架构中，DeepFM 凭借显式二阶特征交互以 AUPRC=0.9336 达到与 XGBoost (0.9331) 统计上不可区分的性能水平 (差距仅 0.0005)，其 ROC-AUC (0.9979) 与 XGBoost 持平；FT-Transformer (0.9179) 经 Sparsemax 替代 Softmax 后性能显著回升 (原 Softmax 版本为 0.8738)，AUPRC 提升超过 4 个百分点，且获得最低业务成本 (Cost=99)。这一对比揭示了归纳偏置设计的关键性：DeepFM 的内积交互 $\langle v_i, v_j \rangle$ 直接建模特征对的协同效应，不依赖“哪些特征更重要”的全局判断，在 PCA 空间中更为稳健。

(3) ROC-AUC 区分度不足。三种模型 ROC-AUC 取值区间极窄 (0.9925–0.9979)，而 AUPRC 区间 (0.9179–0.9336) 区分度更高，验证了在不平衡数据上以 AUPRC 为主要指标的必要性。

(4) 成本-性能非单调。FT-Transformer 成本最低 (99)，而 AUPRC 领先的 DeepFM 和 XGBoost 成本分别为 123 和 215，揭示 AUPRC 最优并非成本最优，模型选择应结合具体业务成本矩阵综合权衡。

图5和6分别展示各模型的 PR 曲线和 ROC 曲线。




图 5: 各模型的 Precision-Recall 曲线，图例标注 AUPRC 值。XGBoost 曲线在多数召回区间高于 DeepFM 和 FT-Transformer，DeepFM 在中等召回区域 (0.7–0.9) 接近 XGBoost。

PR 曲线揭示了模型在不同工作点上的精确率-召回率权衡。如图5所示，XGBoost 的 PR 曲线在召回率 0.4–0.9 的宽区间内均高于 DeepFM 和 FT-Transformer，说明其在多数业务阈值下保持最优的精确率。值得关注的是，DeepFM 在召回率 0.7–0.9 区间几乎与 XGBoost 重合，仅在极高召回端 (>0.92) 出现分离——这意味着如果业务要求检出 92% 以上的欺诈交易，XGBoost 的优势才会实质性地体现。FT-Transformer 的 PR 曲线整体位于 DeepFM 下方，与表2中 AUPRC 排序一致。三条曲线在高召回区域 (>0.95) 均急剧下降，反映了极度不平衡数据下精确率-召回率的内在张力：想要捕获几乎所有的欺诈交易，就必须接受大量的误报。

与 PR 曲线形成鲜明对比，图6中三条 ROC 曲线几乎完全重叠，肉眼难以区分模型优劣。这直观地展示了 ROC-AUC 在不平衡分类问题上的固有缺陷：ROC 曲线以真负率 (TNR) 为横轴，当真负类样本占 99.5% 时，即使模型将所有样本预测为正常，TNR 仍接近 1.0，导致 AUC 虚高。三种模型的 ROC-AUC 范围极窄 (0.9925–0.9979)，而 AUPRC 范围达 0.0157




图 6: 各模型的 ROC 曲线，图例标注 AUC 值，黑色虚线为随机分类器基准。四条曲线均紧贴左上角，视觉差异极小。

(0.9179–0.9336)，后者提供了更高的区分度。这一对比为本文以 AUPRC 为主要评估指标的实验设计提供了实证支持。

主要发现 PR 曲线与 ROC 曲线的对比实验表明：(1) XGBoost 在召回率 0.4–0.9 区间保持精确率优势，DeepFM 在中等召回区域接近 XGBoost；(2) 三条 ROC 曲线几乎重叠，无法有效区分模型；(3) AUPRC 的区分度显著优于 ROC-AUC，验证了不平衡场景下 AUPRC 作为主要评估指标的优越性。

4.2.1 结果分析

从以上定量与可视化结果可以进一步提炼以下深层发现：

- 深度模型 vs. XGBoost 基线：**DeepFM (AUPRC=0.9336) 与 XGBoost (0.9331) 的 AUPRC 差距仅 0.0005，在单一随机种子 (42) 下统计上不可区分。这表明深度模型在大规模表格数据 (15 万 + 样本) 上已具备与树模型同等的实用价值。FT-Transformer (0.9179) 经 Sparsemax 替换 Softmax 后性能大幅回升，与 DeepFM 的差距仅 0.0157，说明适当的稀疏化约束能有效缓解 PCA 空间中注意力塌缩的负面影响。
- 特征交互 vs. 自注意力：**DeepFM 的显式二阶交互以 0.9336 微弱领先 FT-Transformer 的全局自注意力 (0.9179)，差距仅为 1.7 个百分点——相较于旧版 Softmax FTT (0.8738) 的 6 个百分点差距已大幅缩小。Sparsemax 的引入使 FT-Transformer 性能提升 4 个百分点以上。但 DeepFM 仍在两个层面上保有优势：(a) PCA 匿名化削弱了 FT-Transformer 多头注意力所依赖的跨特征语义关联；(b) DeepFM 的内积交互 $\langle v_i, v_j \rangle$ 直接建模特征对的协同效应，不依赖全局特征重要性判断，在 PCA 空间中更为稳健。
- ROC-AUC 的误导性：**各模型 ROC-AUC 差异极小 (0.9925–0.9979，极差仅 0.0054)，而 AUPRC 差异 (0.9179–0.9336，极差 0.0157) 仍约为 ROC-AUC 极差的 2.9 倍。若仅报告 ROC-AUC，可能低估模型间差异。这进一步强化了在不平衡分类问题中使用 AUPRC 作为主要评估指标的必要性。

4.3 树监督蒸馏实验

4.3.1 方法设计

第4节的结果表明，FT-Transformer 的全局自注意力在引入 Sparsemax 后性能已大幅改善 (AUPRC=0.9179)，但其注意力权重仍近乎均匀——Sparsemax 缓解了 Softmax 的完全塌缩 (AUPRC 提升 4 个百分点)，但未能根本解决“哪些特征更重要”这一核心问题。XGBoost 的轴对齐分裂天然知道特征的重要性排序 (通过 split gain)，而 FT-Transformer 必须从零开始学习这一信息，在 PCA 匿名化特征空间中这一学习尤为困难。因此，本文的树监督蒸馏方案旨在弥补这一归纳偏置差距。

受 Tree-Regularized Tabular Embeddings [li2024tree](#) 和 Knowledge Distillation [hinton2015distilling](#) 工作的启发，本文提出 Tree-Supervised 知识蒸馏方案，将 XGBoost 的树归纳偏置迁移至 FT-Transformer。方案包含两个互补组件：

方案 3A: Leaf Soft Label Distillation (软标签蒸馏)。将 XGBoost 的预测概率作为“软标签”，FT-Transformer 以 KL 散度拟合教师的输出分布。总损失函数为：

$$\mathcal{L} = \alpha \cdot \text{FL}(y_s, y) + (1 - \alpha) \cdot T^2 \cdot \text{KL}(p_s^T \parallel p_t^T) \quad (18)$$

其中 FL 为 Focal Loss ($\alpha = 0.25, \gamma = 2.0$)， T 为温度参数 ($T = 4.0$)， α 为硬标签权重 ($\alpha = 0.7$)。温度软化使教师预测中的“暗知识” (如两个高概率类之间的微妙差异) 得以传递，帮助学生学到比硬标签更丰富的决策边界信息。

方案 3B: Feature Split Importance Regularization (特征重要性正则化)。提取 XGBoost 各特征的分裂增益 (split gain)，归一化为特征权重向量 $w \in [0, 1]^{29}$ ，将其作为 FT-Transformer 嵌入层的先验。正则化项为：

$$\mathcal{L}_{\text{reg}} = \lambda \sum_{i=1}^{29} (1 - w_i) \cdot \|\mathbf{E}_i\|_2 \quad (19)$$

其中 $\mathbf{E}_i$ 为第 i 个特征的嵌入向量。该正则化鼓励模型为“低树重要性”特征分配较小嵌入范数，为“高树重要性”特征保留较大表达空间，从而将树模型的轴对齐特征选择偏好注入神经网络。

XGBoost 特征权重 (split gain 归一化) 显示，V14 以 $w_{14} = 1.00$ 占据绝对主导，V12 ($w_{12} = 0.07$) 和 V4 ($w_4 = 0.059$) 为远距第二梯队，其余特征权重均低于 0.02——与 SHAP 分析中 V14 的单特征主导现象一致。

4.3.2 蒸馏实验结果

表 3: 树监督蒸馏定量结果。FTT+KD (3A only) 为新增消融对照——验证 KD 本身是否对 FTT 有效，隔离 TreeReg 的效应。加粗为各指标最优值。

模型	AUPRC	ROC-AUC	F1	Prec	Rec	Cost	ECE
XGBoost (教师)	0.9331	0.9979	0.8750	0.9479	0.8125	215	0.0006
DeepFM (基线)	0.9336	0.9979	0.8938	0.8860	0.9018	123	0.0394
FT-Transformer (基线)	0.9179	0.9925	0.9196	0.9196	0.9196	99	0.0120
FTT + KD (3A only)	0.9347	0.9953	0.9279	0.9364	0.9196	97	0.0007
FTT + KD + TreeReg (3A+3B)	0.8974	0.9945	0.8848	0.9143	0.8571	169	0.0010
DeepFM + KD (3A only)	0.9495	0.9988	0.9058	0.9099	0.9018	120	0.0008

如表3所示，新增的 FTT+KD (仅 3A、不含 TreeReg) 消融实验彻底改变了蒸馏效应的因果归因：

(1) **知识蒸馏对两种架构均有显著增益。**FTT+KD 以 AUPRC=0.9347 相较于 FTT 基线 (0.9179) 提升 1.68 个百分点, 增益幅度与 DeepFM+KD (+1.59pp) 高度一致。这一平行结果推翻了此前“蒸馏是架构依赖的”的初步判断——软标签蒸馏对注意力型 (FTT) 和交互型 (DeepFM) 架构具有同等的正向迁移效应。此外, FTT+KD 的校准近乎完美 (ECE=0.0007, 仅次于 XGBoost 教师), 业务成本降至 97 (全局最低), 且 F1-Score=0.9279 为所有模型最优。

(2) **TreeReg 是退步的唯一元凶。**FTT+KD+TreeReg (3A+3B) 的 AUPRC 仅为 0.8974, 不仅低于 KD 消融对照 (0.9347), 甚至低于未蒸馏的 FTT 基线 (0.9179)。从 FTT+KD (0.9347) 到 FTT+KD+TreeReg (0.8974) 的 -3.73pp 断崖式下降, 将因果链条唯一锁定于 TreeReg (方案 3B): 特征重要性正则化强制 FT-Transformer 的嵌入层模仿 XGBoost 的轴对齐特征偏好 (V14 权重 =1.0, 其余特征权重 <0.07), 这一硬性约束与 Sparsemax 注意力机制对自由特征交互学习的需求形成**结构性拮抗**——注意力需要基于 PCA 空间中特征间的实际语义关联分配权重, 而 TreeReg 将其“锁定”在树模型的单一特征重要性排序上, 导致嵌入空间的信息容量被急剧压缩。需要强调的是, 3A+3B 组合的良好 ECE (0.0010) 进一步印证了这一因果分析: 软标签 (3A) 成功传递了决策边界平滑信息 (ECE 改善), 但 TreeReg (3B) 对嵌入层的刚性约束抵消了 KD 带来的全部 AUPRC 增益。

(3) **校准质量的跨架构一致提升。**所有 KD 变体——FTT+KD (ECE=0.0007)、FTT+KD+TreeReg (ECE=0.0010)、DeepFM+KD (ECE=0.0008)——均取得卓越校准 (ECE<0.002), 验证了 Hinton 等人 [hinton2015distilling](#) 的核心论点: 软标签通过平滑类别边界, 有效降低了深度模型的过度自信。这一效应与架构选择和 TreeReg 的存在均无关, 是 KD 最稳健的收益。

4.3.3 模型参数与归纳偏置

各模型的实际参数量如下: FT-Transformer 为 153,921, DeepFM 为 161,648。XGBoost (300 棵树 × 深度 8) 的等效容量远低于深度模型, 但其 AUPRC (0.9331) 却最优——验证了 Grinsztajn 等人 [grinsztajn2022tree](#) 的观点: 参数数量并非表格数据上性能的决定性因素, 模型的归纳偏置才是关键。这正是本文引入树监督蒸馏的动机: 若能将 XGBoost 的归纳偏置迁移至深度模型, 其额外的参数容量可能转化为真正的性能优势。

5 分析

5.1 可解释性分析

为满足金融风控领域对模型决策透明度的监管要求 (如 GDPR 第 22 条), 本文从三个互补层面展开可解释性分析: (1) 对 XGBoost 进行精确 SHAP 归因 (TreeExplainer), (2) 诊断 FT-Transformer 的注意力权重分布, (3) 在统一置换重要性框架下对比三种架构的行为面特征利用 (第 5.3.4 节)。以下首先呈现 XGBoost 的 SHAP 分析。

5.1.1 SHAP 全局特征重要性

图7展示了 XGBoost 在测试集子集 ($n = 1,000$) 上的 SHAP Beeswarm 摘要图。

分析揭示了三层结构化的特征重要性信息:

(1) **单特征主导:** V14 的平均绝对 SHAP 值 (0.6784) 约为第二名 V12 (0.0475) 的 14.3 倍。这种极端偏斜在金融欺诈检测中具有双重含义: 一方面, 它简化了模型审计——只需监控少数几个关键 PCA 成分的分布偏移即可预警模型衰退; 另一方面, 它也构成了单点故障风险——若攻击者通过对抗手段操纵 V14 对应的原始特征组合, 模型决策可能被系统性绕过。

(2) **特征交互证据:** V4 的散点分布呈现明显的非线性模式——低 V4 值时 SHAP 值接近零, 高 V4 值时 SHAP 值分散为正向和负向两簇。这一“扇形展开”形态是特征交互的典




图 7: XGBoost 的 SHAP Beeswarm 摘要图 ($n=1000$, TreeExplainer)。V14 呈现单特征主导, V12 重要性降至 V14 的约 7%。

型标志: V4 的边际效应依赖于其他特征 (如 V14) 的取值水平。传统的线性重要性排序 (如 Logistic Regression 的系数) 无法捕捉此类条件依赖关系。


(3) PCA 匿名化的分析边界: V1-V28 的具体业务含义无法直接解读, 但 SHAP 重要性排序仍具有操作价值。在实际部署中, 可通过以下方式绕过匿名化限制: (a) 对高 SHAP 值特征, 在特征工程阶段保留其原始语义版本进行配对分析; (b) 利用个体瀑布图逐笔解释拦截决策 (见下节), 满足监管合规要求。

5.1.2 个体预测解释

图8展示了正常交易和欺诈交易两个典型案例的 SHAP 瀑布图。

瀑布图将黑箱预测分解为可追溯的特征贡献序列。图8a中, 正常交易样本的基线预测 ($E[f(x)]$) 约为 0.07, 而 V14 的低值 (相对于训练集均值) 贡献了 -0.32 的负向推动, 加上 V18 (-0.08) 和 Amount (-0.06) 的累积负向效应, 最终将预测概率压低至接近 0。图8b的欺诈案例则展示了镜像模式: V14 的极高值贡献 +0.42 的正向推动, 叠加 V12 (+0.10) 和 V4 (+0.07) 的正向效应, 将预测概率推至接近 1。

这一分析框架直接支持 GDPR 第 22 条的合规要求——当风控分析师需解释拦截决策时, 可引用具体的特征贡献报告: ”该交易被标记为高风险的主要原因是 V14 异常偏高 (贡献 +0.42), 其次为 V12 偏高 (+0.10)。建议人工核验该客户的历史交易模式。” 与传统的”黑箱分数” (如”风险评分 =87 分”) 相比, SHAP 瀑布图提供的逐特征归因显著增强了决策的可审计性和客户申诉的可处理性。



(a) 正常交易样本 (Class=0)。V14 低值等特征将预测概率压低至接近 0。

(b) 欺诈交易样本 (Class=1)。V14 极高值等特征将预测概率推高至接近 1。

图 8: 个体预测 SHAP 瀑布图对比: 正常交易 (左) 与欺诈交易 (右) 的特征贡献路径。

5.1.3 FT-Transformer 注意力分析

图9展示了 FT-Transformer 中 [CLS] Token 对 Top-20 特征的注意力权重。




图 9: FT-Transformer 的 [CLS] Token 注意力权重 ($n=200$)。所有特征注意力高度集中在一个狭窄区间 $[0.0327, 0.0342]$ (均值 0.0334), 与均匀分布基线 ($1/29=0.0345$, 灰色虚线) 几乎重合, 标准差仅 0.0004。

图9揭示了一个重要发现: FT-Transformer 的注意力权重近乎完全均匀。29 个特征的注意力值全部集中在 $[0.0327, 0.0342]$ 的极窄区间内 (均值 0.0334), 与均匀分布基线 $1/29 = 0.0345$ (图中灰色虚线标注) 几乎重合, 标准差仅为 0.0004。换言之, FT-Transformer 的 [CLS] Token 未能有效区分特征的重要性——它在所有特征上分配了近乎相同的注意力。

交叉对比发现两种方法的特征利用模式截然不同: XGBoost 的 SHAP 极端偏斜 (V14 单独占超 60% 重要性), 而 FT-Transformer 的注意力近乎均匀。这一梯度反映了两种架构在 PCA 匿名化特征空间中的表现差异:

- **XGBoost (轴对齐分裂)** 天然擅长发现少数高增益特征维度——每个分裂沿单一特征维度进行, 不受其他维度干扰, 因此在 V14 这类强判别性 PCA 成分上迅速聚焦。
- **FT-Transformer (全局自注意力)** 的 Softmax 注意力缺乏显式的稀疏约束, 多头机制虽设计了多个“注意力视角”, 但在 PCA 破坏特征语义关联后, 各头无法形成有意义的特征子空间划分, 导致注意力退化为近乎均匀的“平均投票”。本文虽已用 Sparsemax 替代 Softmax 以引入稀疏性, 但实验 (第五节) 表明该替换的增益有限——注意力塌缩的根源不在于归一化函数的选择, 而在于 PCA 空间本身缺乏可供注意力机制利用的跨特征语义关联。

这一发现直接解释了 FT-Transformer 为何在深度模型中表现最差：当特征经过 PCA 匿名化后，全局自注意力的 Query-Key 内积趋向于同一常数值，注意力权重丧失特征的相对重要性信号。但需要指出，注意力均匀化也可能是 Focal Loss ($\alpha = 0.25$) 的间接效应—— $\alpha = 0.25$ 的高正类权重可能将大部分梯度预算分配给分类边界的调整，注意力权重被动地保持在接近初始化的均匀状态。区分“PCA 空间导致的注意力塌缩”与“Focal Loss 导致的注意力锁定”需要以标准交叉熵 (BCE) 为对照的消融实验，这超出了当前实验范围。相比之下，DeepFM 的显式内积交互 $\langle v_i, v_j \rangle$ 直接建模特征对的协同效应，不依赖“哪些特征更重要”的全局判断，因此在 PCA 空间中更为稳健。由此，本文的树监督蒸馏方案 (第五节) 另辟蹊径：不试图在 PCA 空间中“修复”注意力，而是通过 XGBoost 教师注入外部特征重要性信号，从数据驱动的“特征重要性学习”转向先验注入的“特征重要性继承”。

5.1.4 跨模型置换特征重要性对比

上述 SHAP 和注意力分析分别以模型特定的视角揭示了 XGBoost 和 FT-Transformer 的特征利用模式。然而，三者及其蒸馏变体尚未在同一可解释性框架下直接比较。为此，本文采用模型无关的置换特征重要性 (Permutation Feature Importance) ——逐一打乱各特征列并测量 AUPRC 下降幅度——在统一的坐标下对比全部六个模型：教师 (XGBoost)、基线学生 (DeepFM、FTT) 和三种蒸馏变体 (DeepFM+KD、FTT+KD、FTT+KD+TreeReg)：




图 10: 全模型置换特征重要性对比 ($n=5$ 次重复, 全量测试集 22,613 样本)。Panel A: XGBoost 教师的特征优先级; Panel B: DeepFM 基线 vs DeepFM+KD——KD 对 FM 架构的影响; Panel C: FTT 基线 $\rightarrow$ FTT+KD $\rightarrow$ FTT+KD+TreeReg——KD 增益与 TreeReg 破坏的逐级分解。水平柱为 AUPRC 下降均值 $\pm$ 标准差。

图10和图11揭示了五个层面的跨模型特征利用模式：

(1) **软标签蒸馏将学生拉向教师的特征排序**。KD 对特征重要性排序的影响可通过学生与教师的 Pearson 相关性量化：对 DeepFM, $r(\text{XGBoost}, \text{DeepFM})$ 从基线的 0.625 提升至 KD 后的 0.845 (+0.220)；对 FTT, $r(\text{XGBoost}, \text{FTT})$ 从基线的 0.793 微调至 0.771——与 DeepFM 不同，FTT 的 KD 不通过复制教师的特征偏好来获益，而是通过校准质量的大幅改善 (ECE 从 0.0120 降至 0.0007) 实现性能提升。这一对比揭示了 KD 在不同架构上的两种互补作用机制：(a) 对 FM 架构，KD 通过软标签传递了教师的特征优先级结构；(b) 对注意力架构，KD 主要通过提升概率校准而非重塑特征重要性来增益。

(2) **TreeReg 制造了特征重要性的“XGBoost 复刻”但性能崩溃**。FTT+KD+TreeReg 与 XGBoost 的特征重要性排序相关性高达 $r=0.964$ ——近乎完美的复刻。然而，这一“对齐”的代价是 V14 集中度从 FTT+KD 的 17.0% 激增至 43.9% (与 XGBoost 教师的 44.0% 几乎一致)，其余特征的重要性被系统性压制——在 Top-16 特征中，8 个特征的置换效应趋近于零或变为负值。TreeReg 通过嵌入层范数正则化将教师的轴对齐特征偏好刚性注入注意力架构，

使 FTT 退化为一个事实上的 XGBoost 粗糙代理——失去了自注意力分布式交互的优势，却未获得树模型的分裂效率。这为第 5.2.3 节消融实验中的断崖式性能下降（-3.73pp，AUPRC 从 0.9347 降至 0.8974）提供了机制层面的解释：**TreeReg 不是”过强的正则化”，而是对注意力型架构的特征利用模式实施了结构性替代。**

(3) KD 提升跨架构行为相似性。蒸馏前， $r(\text{DeepFM}, \text{FTT})$ 仅为 0.639——FM 的显式交互与自注意力的隐性交互在特征利用上存在本质分歧。KD 后， $r(\text{DeepFM}+\text{KD}, \text{FTT}+\text{KD})$ 提升至 0.806 (+0.167)——两个异质学生从同一位树教师处学到的软标签信号，使它们在”使用了哪些特征”这一行为面上显著趋同。这是跨架构知识迁移的间接证据：软标签不仅传递了决策边界，还隐式传递了教师的特征重要性结构。

(4) V14 跨架构共识及其蒸馏调制。全部六个模型均将 V14 识别为首要特征——其置换效应占总重要性的比例从 DeepFM+KD 的 15.7% 到 FTT+KD+TreeReg 的 43.9% 不等。V4 为众口一词的第二重要特征（占比从 DeepFM 的 9.7% 到 FTT+KD 的 34.2%）。这一跨架构一致性验证了 SHAP 分析中 V14 单特征主导的结论——其对预测的贡献不依赖于特定模型的归纳偏置，而是 PCA 空间中固有的强判别性信号。

(5) DeepFM 的分布式特征利用经 KD 后得以保持。DeepFM 基线的重要性呈现出比 XGBoost 显著更平坦的分布——V14 (0.166) 仅占总重要性的 14.7%，V3 (0.159) 和 V12 (0.157) 与之接近。KD 后，V14 集中度仅微增至 15.7%，模型的分布式特征利用模式基本保持不变——这与 DeepFM+KD 取得全局最优 AUPRC (0.9495) 一致：KD 在不破坏 FM 架构的多样化特征交互的前提下，注入了教师的高质量校准信号。

	XGBoost	DeepFM	DFM+KD	FTT	FTT+KD	FTT+KD+T
V14 (ΔAUPRC)	0.142	0.166	0.071	0.058	0.156	0.377
V4 (ΔAUPRC)	0.088	0.110	0.079	0.087	0.313	0.218
V14 占比 (%)	44.0	14.7	15.7	12.8	17.0	43.9
$r(\text{XGBoost}, \cdot)$	1.000	0.625	0.845	0.793	0.771	0.964

图 11: 置换重要性关键指标对比。V14 占比为 V14 置换效应占该模型全部特征置换效应之和的百分比。 r 为与 XGBoost 教师的 Pearson 排序相关系数。FTT+KD+T=FTT+KD+TreeReg。

置换重要性分析补全了本文可解释性矩阵的最后一块拼图——SHAP 提供 XGBoost 的精确归因，注意力揭示 FTT 的”表达面”特征利用，而置换重要性在统一框架下覆盖全部模型变体的”行为面”特征依赖，并揭示了 KD 和 TreeReg 对特征利用模式的截然相反的调制方向：前者在保持架构原生特征分布的前提下注入校准知识，后者则强行重写特征优先级而导致性能崩塌。三者共同构成了从”看了什么”（注意力）到”用了什么”（置换重要性）再到”每个特征贡献了多少”（SHAP）的完整可解释性阶梯。

SHAP 仅衡量个体贡献，本文采用 Shapley Interaction Index (SII) 进行二阶分析：

$$\Delta_{ij}(T) = \nu(T \cup \{i, j\}) - \nu(T \cup \{i\}) - \nu(T \cup \{j\}) + \nu(T)$$

正值表示协同效应，负值表示冗余。

SII 分析揭示了两个层面的特征关系：(1) **V14 的一阶与二阶双重支配**——V14 不仅在一阶 SHAP 值中排名第一 (0.6784)，其参与的特征对（如 V14-V12、V14-V4）也占据了 SII 热力图的最强信号区域，说明 V14 的预测能力部分来源于其与其他特征的协同效应而非单纯的独立贡献；(2) **正负交互并存**——热力图中同时存在深色（正 SII，协同）和浅色（负 SII，冗余）区域，例如 V14-V12 对呈现正交互（两特征同时偏高时欺诈概率超出各自独立贡献之和），而部分高编号 V 特征对呈现负交互（信息重叠）。这一发现对特征工程有直接指导：正 SII 特征对应被保留并构造交叉特征，负 SII 特征对可考虑降维或剔除其一以减少冗余。

PCA 匿名化限制了 SII 结果向业务语言的映射——我们无法将”V14-V12 协同”翻译为”交易金额与商户类别的交互效应”。但在方法论层面，SII 为 PCA 降维后的特征空间提供了




图 12: XGBoost 的 Top-15 特征对 SII 热力图 ($n=50$, shapig TreeSHAP-IQ)。V14 为中心的特征对交互最强。

标准化的二阶分析工具，这一流程可直接应用于具有语义标签的数据集。

5.2 概率校准分析

本文以 Expected Calibration Error (ECE) 量化校准质量：

$$\text{ECE} = \sum_{b=1}^B \frac{n_b}{N} |acc(b) - conf(b)|$$

表 4: 各模型的 Expected Calibration Error。XGBoost 校准优秀 ($\text{ECE} < 0.001$), FT-Transformer 校准良好 ($\text{ECE} = 0.0120$), DeepFM 校准一般 ($\text{ECE} = 0.0394$)。

模型	ECE	校准评价
XGBoost	0.0006	优秀
FT-Transformer	0.0120	良好
DeepFM	0.0394	一般

表4显示 XGBoost ($\text{ECE} = 0.0006$) 校准优秀, FT-Transformer ($\text{ECE} = 0.0120$) 校准良好, DeepFM ($\text{ECE} = 0.0394$) 校准一般。值得注意的是, FT-Transformer 的校准质量相比旧版 Softmax 版本 ($\text{ECE} = 0.2328$) 提高了近 20 倍——Sparsemax 替代 Softmax 后, 注意力权重在保持近均匀分布的同时, 模型的概率输出置信度显著更接近真实频率。这是 Sparsemax 为 FT-Transformer 带来的最大实证收益: AUPRC 提升约 4 个百分点, ECE 从“不可用” (0.2328) 降至“良好” (0.0120), 且业务成本从 269 降至 99。DeepFM 虽使用 $\alpha = 0.995$ 的 Focal Loss (对正类施加约 200 倍梯度权重), 其 ECE (0.0394) 仍处于一般水平, 说明其显式二阶交互结构具有一定的校准正则化效果, 但不如 XGBoost 的树结构稳健。FT-Transformer 和 DeepFM 均可通过 Platt Scaling 后处理将 ECE 进一步降低至 0.01 以下。




图 13: 各模型的可靠性图。蓝色柱为各概率区间的实际正类率，黑色虚线为完美校准，ECE 标注于子图标题。

5.3 商业成本分析

模型业务价值取决于误报 (FP) 和漏报 (FN) 造成的实际经济损失：

$$\text{Cost} = C_{FP} \times \text{FP} + C_{FN} \times \text{FN}, \quad C_{FP} = 1, \quad C_{FN} = 10$$

10:1 的比例参考了银行业欺诈检测的成本估算惯例 [dastidar2024survey](#)。




图 14: 各模型在成本矩阵 ($C_{FP}=1, C_{FN}=10$) 下的总成本对比。横条越短表示业务损失越小，FT-Transformer 成本最低 (167) 而 XGBoost 最高 (215)。

图14揭示：(1) **AUPRC 最优 $\neq$ 成本最优**——DeepFM 和 XGBoost 的 AUPRC 最高 (0.9336/0.9331) 但成本分别为 123 和 215，FT-Transformer 成本最低 (99) 且 AUPRC 达到 0.9179；(2) **帕累托前沿**——不同模型在精度-成本平面上构成权衡边界；(3) **成本比敏感性**——本文采用 $C_{FP} : C_{FN} = 1 : 10$ [dastidar2024survey](#)，若该比例增大（如 1:50，适用于高额交易场景），则召回率最高的模型（如 FT-Transformer，Recall=0.9196）将更具成本优势；

反之若比例缩小（如 1:2），精确率权重上升，XGBoost（Precision=0.9479）的优势将进一步扩大。因此，具体模型选择需结合银行的实际欺诈损失与审核成本数据。

5.4 模型选择建议

综合实验与分析发现，针对不同业务场景的模型选择建议如下：

表 5: 面向不同业务需求的模型选择建议。选择逻辑由精度、可解释性、校准质量和成本敏感性四个维度驱动，不存在单一最优模型。

业务场景	推荐模型	理由
追求最高检测精度	XGBoost	AUPRC 全局最优，精确率最高
可解释性优先	XGBoost + SHAP	TreeExplainer 精确计算，瀑布图支持逐笔解释
深度模型偏好	DeepFM	深度模型中 AUPRC 最高（0.9336），与 XGBoost 统计上不可区分
概率校准要求高	XGBoost	ECE < 0.001，可直接用于风险评分
成本敏感场景	依成本比动态选择	$C_{FN}/C_{FP} > 10$ 时倾向 FT-Transformer，< 5 时倾向 XGBoost

表5的选择逻辑体现了本文的核心立场：不存在单一”最佳”模型，模型选择应由业务约束驱动。具体而言：（1）在监管严格的场景（如欧盟 GDPR 管辖区），可解释性可能比 0.01 的 AUPRC 提升更具合规价值；（2）在实时风控系统中，XGBoost 的推理速度（微秒级）和概率校准（ECE=0.0006）使其成为天然首选；（3）在需要频繁模型更新的场景（如应对新型欺诈模式），DeepFM 的端到端可微分训练允许在新数据上进行增量微调，而 XGBoost 需要全量重训练。这些业务维度的考虑将模型选择从纯技术决策提升为风险管理决策。

6 讨论

6.1 商业启示

实验表明，DeepFM（AUPRC=0.9336）与 XGBoost（0.9331）在统计上不可区分，FT-Transformer 经 Sparsemax 优化后（0.9179）也大幅缩小了与树模型的差距。关键消融实验（FTT+KD vs. FTT+KD+TreeReg）揭示了全新的因果图景：软标签蒸馏（3A）对两种异构深度架构具有同等的正向增益（FTT+KD: +1.68pp, DeepFM+KD: +1.59pp），而特征重要性正则化（3B）是导致 FTT 蒸馏失败的**唯一元凶**——TreeReg 对嵌入层的轴对齐约束使 FTT 从 0.9347 断崖式退步至 0.8974（-3.73pp）。这一发现将论文的核心贡献从笼统的”蒸馏架构依赖性”精确为”树先验正则化与自注意力机制的结构性不兼容”，为未来注意力型架构的蒸馏策略设计提供了明确的避坑指南：软标签可以放心用，嵌入层正则化需要避开。

6.2 局限性

本研究存在以下局限性：

1. **数据集单一**：仅在单个 Kaggle 数据集上评估，特征经 PCA 匿名化丧失原始语义。模型在其他真实银行数据集上的泛化性能有待验证。
2. **实现一致性问题**：FT-Transformer 和 DeepFM 因官方库在当前环境下无法安装或不适配，使用手写实现，与原论文的严格对齐度可能略低于官方库。

3. **缺乏统计显著性检验**: 因计算资源限制, 每个模型仅运行一次 (单一随机种子 42), 未进行多随机种子的 Wilcoxon 检验或配对 t 检验。因此, 当前排名 ($\text{DeepFM} \approx \text{XGBoost} > \text{FT-Transformer}$) 的统计显著性无法确定, 尤其是 DeepFM (0.9336) 与 XGBoost (0.9331) 之间的 AUPRC 差异仅 0.0005, 几乎可以忽略。理想实验设计应包含至少 15 个随机种子并报告均值和置信区间 `grinsztajn2022tree`。
4. **实验设计问题**: FTT+KD 消融实验已完成 ($\text{AUPRC}=0.9347$), 成功将 TreeReg 的负效应从 KD 的正效应中分离——但该结果尚需多随机种子验证。此外, 蒸馏温度 $T = 4.0$ 和软标签权重 $\alpha = 0.7$ 未经网格搜索, 不同 T/α 组合可能影响结论的稳健性。TreeReg 仅对 FTT 测试, 其对 DeepFM 的影响未评估——即 TreeReg 是否也对 FM 架构有害仍属未知。
5. **概念漂移与对抗鲁棒性**: 欺诈模式随时间演化, 静态评估无法反映模型对新型欺诈的表现。高级攻击者可能通过对抗样本规避检测。

6.3 未来工作

基于本研究的发现和局限, 未来可按以下优先级展开:

- **近期 (1-2 年)**: 引入 SAINTsomepalli2022saint 的 intersample attention 机制; 实现多随机种子统计检验; 补充 FT-Transformer 的 rtdl 官方库对比。
- **中期 (2-3 年)**: 将图神经网络与交易图谱结合捕获结构化欺诈模式; 集成概念漂移检测算法实现模型持续适应。
- **远期**: 探索联邦学习下的多机构隐私保护协作训练; 与多模态数据 (行为序列、设备指纹) 的深度融合。

7 结论

本文针对信用卡欺诈检测这一商业智能问题, 比较了两种异构深度神经网络架构 (FT-Transformer、DeepFM) 与 XGBoost 基线的性能, 并提出了 Tree-Supervised 知识蒸馏方案将 XGBoost 的树归纳偏置迁移至深度模型。主要发现如下:

1. **DeepFM 与 XGBoost 统计不可区分**: DeepFM ($\text{AUPRC}=0.9336$) 达到与 XGBoost (0.9331) 统计上不可区分的性能水平 (单一随机种子下差距仅 0.0005)。DeepFM 的显式二阶交互在 PCA 匿名化特征空间中展现出高度鲁棒性。
2. **Sparsemax 拯救了 FT-Transformer**: FT-Transformer 经 Sparsemax 替代 Softmax 后, AUPRC 从 0.8738 跃升至 0.9179 (+4.4 个百分点), ECE 从 0.2328 降至 0.0120 (+20 倍校准改善), 业务成本从 269 降至 99。Sparsemax 的稀疏性约束有效缓解了注意力塌缩问题, 但注意力分布仍近乎均匀, 说明 PCA 空间本身缺乏供注意力机制利用的跨特征语义关联。
3. **TreeReg 而非 KD 与自注意力形成拮抗**: FTT+KD 消融实验以 $\text{AUPRC}=0.9347$ (+1.68pp vs. 基线, $\text{ECE}=0.0007$) 证明软标签蒸馏对注意力型架构同样高效——推翻了此前“蒸馏是架构依赖的”的预判。FTT 从 KD 获益 (+1.68pp) 与 DeepFM (+1.59pp) 高度一致。真正的罪魁是 TreeReg (3B): 特征重要性正则化将 FTT 从 0.9347 断崖式拖降至 0.8974 (-3.73pp), 揭示树先验对嵌入层的刚性约束与 Sparsemax 注意力的自由交互学习之间存在结构性冲突。软标签蒸馏是跨架构安全的性能倍增器, 嵌入层正则化对注意力模型则是精确的“毒药”。

4. **商业成本矩阵至关重要**: FTT+KD 实现最低业务成本(97), 而 AUPRC 领先的 DeepFM+KD 成本为 120, XGBoost 为 215, 揭示了精度与成本间的非单调关系, 为业务决策提供帕累托前沿分析依据。

综上, 深度表格模型在信用卡欺诈检测领域已展现出与 XGBoost 匹敌的潜力——DeepFM+KD 以 AUPRC=0.9495 确立最优性能, FTT+KD 以 0.9347 和 ECE=0.0007 实现最佳校准与最低成本 (Cost=97)。Tree-Supervised 蒸馏的消融实验揭示了明确的因果图: 软标签蒸馏 (3A) 是跨架构安全且高效的 (FTT+1.68pp, DeepFM+1.59pp), 而 TreeReg (3B) 对注意力型架构的嵌入层施加了破坏性约束 (-3.73pp), 但对交互型架构 (DeepFM) 未测试——这一不对称性是未来研究的明确方向。未来工作应聚焦于 SAINT 架构的引入、为注意力模型设计去冲突的树先验注入方式、以及多随机种子统计检验。

本研究为商业智能课程的实践学习提供了完整的端到端案例: 从数据集获取与预处理、多个深度学习模型的实现与训练、多维度的评估分析, 到基于可解释性的商业决策支持。