

金融隐私数据环境下的自注意力塌缩

——以信用卡欺诈检测为例的诊断、修复与机制分析

摘要

在金融反欺诈的行业实践中，数据隐私法规（如《个人信息保护法》、GDPR）要求跨机构共享的客户数据必须经过匿名化处理，PCA 匿名化正是最常见的脱敏手段之一。然而，当深度学习模型（以 Transformer 为代表）被应用于此类丧失了语义身份的特征数据时，其赖以工作的自注意力机制可能发生系统性塌缩——所有特征被等权对待，模型的决策过程丧失了可区分性和可解释性。本文以信用卡欺诈检测为具体场景，在 Kaggle 2023 数据集（29 维 PCA 匿名化特征，0.5% 欺诈率）上通过五个 FT-Transformer 变体的受控实验，对这一问题进行了系统诊断。核心发现：（1）PCA 匿名化特征空间中，Softmax 自注意力塌缩为均匀分布（标准差仅为均匀基线的 3.6%），根因是特征嵌入的方向同构性，Focal Loss 进一步将塌缩放大了 $\times 3.3$ ；（2）三种修复路径各有边界，且**没有任何模型在所有指标上全面占优**——归一化端 Sparsemax 恢复多样性 $\times 7.5$ （AUPRC 0.9384，Cost 最优）、损失端 BCE AUPRC 和校准均最优（0.9491，ECE=0.0001）、数据端 LOR-MIM 恢复多样性最显著（ $\times 11.2$ ，F1 最优）；（3）LOR-MIM 与 Sparsemax 联合使用揭示数据端与归一化端修复之间存在结构性拮抗——注意力多样性进一步提升（ $\times 16.5$ ），但 AUPRC 反而下降（0.9267）。本文的实践意义在于：为金融机构在匿名化数据上应用深度学习时面临的“模型是否可信”问题，提供了一套可操作的诊断流程和基于特征匿名化程度的模型选型参考。

关键词：自注意力塌缩；PCA 匿名化；金融隐私数据；FT-Transformer；Sparsemax；LOR-MIM

Abstract

Cross-institutional anti-fraud collaboration requires customer data to be anonymized under privacy regulations such as GDPR, with PCA-based anonymization being a widely adopted technique. However, when deep learning models—particularly Transformers—are applied to such privacy-preserving features, the self-attention mechanism may undergo systematic collapse: all features receive near-uniform weights, rendering model decisions both uninterpretable and potentially unreliable. Using credit card fraud detection on the Kaggle 2023 dataset (29 PCA-anonymized features, 0.5% fraud rate), we conduct controlled experiments across five FT-Transformer variants. Key findings are threefold. First, Softmax attention collapses to a quasi-uniform distribution (standard deviation only 3.6% of the uniform baseline), with PCA-induced embedding homogeneity as the root cause and Focal Loss amplifying collapse by $\times 3.3$. Second, three repair paths show distinct boundaries with **no single model dominating all metrics**: Sparsemax restores diversity $\times 7.5$ (AUPRC 0.9384, best Cost), BCE achieves best AUPRC and near-perfect calibration (0.9491, ECE=0.0001), and LOR-MIM yields strongest diversity ($\times 11.2$, best F1). Third, combining LOR-MIM with Sparsemax reveals structural antagonism between repair paths—diversity reaches $\times 16.5$, yet AUPRC drops below Sparsemax alone (0.9267 vs. 0.9384). We contribute a diagnostic framework for attention collapse under feature anonymization, together with practical model-selection guidance for financial institutions deploying deep learning on privacy-protected data.

Keywords: attention collapse; PCA anonymization; financial privacy data; FT-Transformer; Sparsemax; LOR-MIM

1 引言

1.1 研究动机：金融数据隐私与深度学习的张力

金融反欺诈是商业智能的核心应用场景之一。然而在实际业务中，银行和金融机构之间的数据共享面临严格的隐私合规约束——《个人信息保护法》要求跨机构共享的客户数据须经脱敏处理，GDPR 对个人数据的跨境传输施加了明确限制。PCA 匿名化（即将原始特征变换为主成分后发布）因其实现简单、数学性质清晰，成为金融数据对外共享中最常见的匿名化手段。例如，Kaggle 上广泛使用的信用卡欺诈检测数据集即采用了这一处理——28 个原始特征被变换为 28 个 PCA 主成分，仅保留交易金额（Amount）作为唯一可识别的业务变量。

这一行业实践带来一个被忽视但至关重要的问题：**当深度学习模型应用于此类经 PCA 匿名化处理的金融数据时，其核心机制是否仍能正常工作？**

自注意力机制 [1] 是 Transformer 架构 [2] 的核心计算原语。在正常条件下，它通过 Query-Key 内积衡量特征间的语义关联，据此为不同特征分配差异化的注意力权重。然而这一机制的有效运行依赖于一个隐含前提——输入特征具有可区分的语义身份。当特征经过 PCA 匿名化后，V1-V28 等“特征”不再是“交易金额”或“商户类别”这些具有独立业务语义的变量，而是原始特征空间中主成分方向上的坐标值。它们的数学属性高度同构：同样的尺度，同样的分布形态，同样的构造方式。在此条件下，Query-Key 内积可能在所有特征对上产生近乎相同的值——注意力机制退化为对所有特征的等权平均，模型的决策过程丧失可区分性和可解释性。

这一问题对金融风控具有直接的商业影响：如果风控模型无法区分“哪个特征更重要”，业务人员就无法理解模型的决策依据，监管合规要求的模型可解释性也无法满足。此外，被等权聚合的特征中若包含与欺诈无关的噪声，将直接损害模型的排序精度。

Gorishniy 等人 [3] 发现 FT-Transformer 在部分表格数据集上表现优异，但未系统分析特征匿名化对注意力行为的影响。Grinsztajn 等人 [4] 指出无信息特征对自注意力的干扰可能比树模型更严重。Borisov 等人 [5] 在表格深度学习综述中强调特征结构对注意力有效性的重要性。然而，现有文献均未将“金融数据隐私化 → 特征匿名化 → 注意力失效”作为一个完整的因果链来考察。

本文以信用卡欺诈检测为具体场景，聚焦于一个对金融行业有直接操作意义的问题：**当金融机构使用的数据经过 PCA 匿名化处理，深度学习模型的自注意力机制是否会系统性失效？若会，失效的根因是什么，有哪些可行的修复路径，各路径的边界在哪里？**

1.2 研究问题

1. **诊断问题**：FT-Transformer 的自注意力在 PCA 匿名化金融数据中是否塌缩为均匀分布？根因是特征嵌入的方向同构性，还是 Focal Loss 对不平衡数据处理的副作用？
2. **修复边界问题**：两条修复路径——归一化端（Sparsemax）和数据端（LOR-MIM）——各自的有效范围是什么？联合使用是否存在协同或拮抗？

1.3 核心发现

1. **PCA 嵌入同构为塌缩根因**：特征嵌入的 SVD 分析确认 29 个嵌入向量几乎全部位于 3-4 个主方向张成的低维子空间，嵌入层有效秩远低于名义维度。
2. **两条修复路径各有边界，无模型全面占优**：最优 AUPRC/Cost 属于 Sparsemax (0.9384, 97)，最优 F1 属于 LOR-MIM+Softmax (0.9358)，最优注意力/ECE 属于 LOR-MIM+Sparsemax ($\times 16.5$, ECE=0.0066)。
3. **数据端与归一化端存在结构性拮抗**：LOR-MIM+Sparsemax 联合使用使多样性达 $\times 16.5$ ，但 AUPRC 反低于 Sparsemax 单独使用 (0.9267 vs 0.9384) ——LOR-MIM 的混合破坏了 Sparsemax 稀疏选择的 logits 序关系。

1.4 论文贡献

1. **商业场景贡献**：明确将金融数据隐私化与深度学习模型失效之间的因果链纳入系统分析，为金融机构在匿名化数据上的模型选型提供了实证依据。
2. **诊断贡献**：提供了自注意力塌缩的三层证据链（注意力权重 → 嵌入 SVD → 多头多样性）和可操作的诊断模板。
3. **方法贡献**：提出 LOR-MIM——仅需 305 参数的数据端对称破缺方法，并揭示其与 Sparse-max 之间的结构性拮抗关系。

1.5 论文组织

第2节介绍数据来源及金融匿名化背景；第3节回顾 FT-Transformer 架构、给出塌缩形式化定义并介绍 LOR-MIM 方法；第4节描述实验设置；第5节呈现五变体对照结果；第6节进行深层机制诊断；第7节总结全文并给出金融实践建议。

2 数据来源与探索性分析

2.1 数据来源与金融匿名化背景

本文采用 Kaggle 平台上的 Credit Card Fraud Detection Dataset 2023[6]。该数据集包含欧洲信用卡持卡人的真实交易记录，原始数据共 568,630 条交易，31 个特征列：一个交易 ID 列 (id)、28 个经 PCA 匿名化处理的特征 (V1-V28)、交易金额 (Amount) 和类别标签 (Class, 0= 正常交易, 1= 欺诈交易)。

PCA 匿名化在此数据集集中的使用并非学术实验的人为设计，而是金融行业数据共享实践的缩影。出于客户隐私保护和监管合规要求，金融机构在对外发布或跨机构共享交易数据时，必须对涉及个人身份和财务行为信息的原始特征进行脱敏。PCA 通过将原始特征投影到一组彼此正交的主成分上，在保留数据全局方差结构的同时，使得攻击者无法直接还原原始特征的具体含义或反推特定客户的身份信息。正因如此，Kaggle 等公开数据平台上的金融数据集普遍采用 PCA 匿名化处理——这一“行业惯例”恰好构成了本文研究问题的现实基础。需要特别指出，本文并不批评 PCA 匿名化本身——从隐私保护角度它是合理且必要的——而是诊断在其之上叠加深度学习模型时产生的意外后果。

数据集的类别平衡处理如下。原始数据中正负类接近 1:1 平衡（欧洲信用卡交易的真实欺诈率通常在 0.1%–1% 之间）。为模拟真实场景中约 0.5% 的欺诈发生率，本文对多数类（正常交易）进行随机下采样并限制最大样本数为 150,000 条，同时从少数类（欺诈交易）中随机抽取 750 条，使最终欺诈比例约为 0.5%（正负比约 1:200）。这一处理对于本研究的实验目的——在极度不平衡条件下诊断自注意力的行为——是必要的。

2.2 数据集特征

经处理后的数据集包含 150,750 条记录（150,000 正常 + 750 欺诈），29 个数值型特征 (V1-V28 + Amount)，无缺失值。

图1呈现了经不平衡处理后的完整数据集类别分布：正常交易样本数为 150,000，欺诈交易样本数仅为 750，正负类比例约为 200:1。这种极端的类别不平衡是信用卡欺诈检测任务的核心挑战——模型在训练过程中极易被多数类主导，导致对少数类的识别能力严重退化。仅 0.5% 的欺诈比例意味着，即使一个“将所有交易预测为正常”的朴素分类器也能达到 99.5% 的准确率——这正是准确率 (Accuracy) 在不平衡场景下完全失效的原因，也解释了本文为何采用 AUPRC 而非准确率作为主要评估指标。

图2以核密度估计对比了两类交易的金额分布。蓝色曲线（正常交易， $n=150,000$ ）和橙色曲线（欺诈交易， $n=750$ ）均呈现明显的右偏（长尾）分布，但存在两个关键差异：第一，欺诈交易的 KDE 峰值位置略高于正常交易，表明欺诈者倾向于选择中等偏高的交易金额以在“隐匿性”与“收益”之间取得平衡；第二，在高金额区间 ($> 15,000$ 标准化单位)，欺诈交易




图 1: 经不平衡处理后的数据集类别分布。正常交易 150,000 条，欺诈交易 750 条，正负比约 200:1，准确率在此场景下完全失效。

的密度相对更高，这与银行业务经验一致——高价值交易是欺诈者的优先目标。然而，两类分布在整体上存在大量重叠区域，意味着仅凭交易金额远不足以区分欺诈与正常交易，必须依赖多维特征联合判别。




图 2: 正常交易与欺诈交易的金额核密度估计曲线。蓝色为正常交易，橙色为欺诈交易，两类均呈右偏分布且存在大量重叠，欺诈交易在高金额区间密度略高。

2.3 数据预处理

预处理流水线包含以下步骤：

1. **特征选择**：移除 ID 列（不携带预测信息），保留 28 个 PCA 特征和 Amount 共 29 个特征。
2. **异常值处理**：对 Amount 特征采用 IQR 方法进行异常值截断 ($Q1 - 1.5 \times IQR$ 至 $Q3 + 1.5 \times IQR$)，仅在训练集上计算上下界以避免数据泄露。V1-V28 为 PCA 变换后的特征，其分布为原始特征的线性组合，不具有传统意义上的“异常值”含义，因此不做截断处理。
3. **标准化**：使用 StandardScaler 对所有 29 个数值特征进行标准化（均值为 0，标准差为 1），仅在训练集上拟合参数，应用于验证集和测试集。
4. **数据集划分**：按 70%/15%/15% 比例进行分层划分 (Stratified Split)，确保各子集中欺诈

比例一致。最终产出：训练集 105,525 条，验证集 22,613 条，测试集 22,612 条。

上述 EDA 和预处理结果表明：(1) 任何有效的检测模型必须采用针对性的不平衡处理策略，因为 0.5% 的欺诈率使标准分类器失效；(2) 多特征联合判别是必需的，因为单一金额特征区分度不足；(3) 评估时必须使用对类别不平衡敏感的指标（AUPRC 而非准确率或 ROC-AUC）；(4) 所有 V1-V28 特征为 PCA 匿名化后的成分——这一事实贯穿全文，是注意力塌缩发生的结构性前提。

3 FT-Transformer 与自注意力机制

本章介绍 FT-Transformer 的架构原理，并在此基础上建立理解注意力塌缩所需的概念框架。全章共分四部分：(1) FT-Transformer 的四层架构，(2) Softmax 与 Sparsemax 的数学性质对比，(3) 自注意力的信息论视角，(4) 注意力塌缩的形式化定义。与原始论文 [3] 的叙述不同，本文的架构讲解始终围绕一个核心问题展开——自注意力机制在表格数据上的有效运行需要满足哪些前提条件？

3.1 FT-Transformer 架构

FT-Transformer (Feature Tokenizer + Transformer) 由 Gorishniy 等人 [3] 于 2021 年提出，其核心思想是将表格数据的每个数值特征视为一个独立的“词元” (Token)，通过 Transformer 编码器的自注意力机制学习特征间的全局交互。图3以流程图呈现了从原始特征到最终预测的完整数据流。




图 3: FT-Transformer 架构流程图。29 个数值特征经 Feature Tokenizer 映射为 64 维嵌入向量，前置可学习的 [CLS] Token 后送入 3 层 Transformer 编码器，最终由 [CLS] 输出经 LayerNorm 和线性层得到预测概率。

3.1.1 Feature Tokenizer: 数值特征嵌入

传统做法将表格数据的一行直接输入 MLP ($\mathbb{R}^{29} \rightarrow \text{Linear}(29, 64)$)，等价于对所有特征使用同一个投影矩阵。FT-Transformer 的关键创新在于为每个特征 j 分配独立的可学习参数 $\mathbf{W}_j$ 和 $\mathbf{b}_j$ ：

$$T_j = x_j \cdot \mathbf{W}_j + \mathbf{b}_j \in \mathbb{R}^{d_{\text{model}}} \quad (1)$$

其中 $\mathbf{W}_j$ 的作用不是线性变换（因为 x_j 是标量），而是**特征专属的嵌入方向**——将标量特征值沿特定方向拉伸为 d_{model} 维向量。这一设计的关键意图是为后续是自注意力提供可区分的 Query/Key：不同特征的嵌入位于向量空间的不同方向，使得 Query-Key 内积能够产生有信息量的注意力分布。然而，这一设计的有效性取决于一个隐含假设——特征本身具有足够的异质性，使得嵌入层能够学习到有意义的方向差异。本文的第6节将检验这一假设在 PCA 匿名化特征空间中的成立程度。

3.1.2 [CLS] Token 与分类头

借鉴 BERT[7] 的设计，FT-Transformer 在所有特征令牌前添加一个可学习的 [CLS] Token $T_{CLS} \in \mathbb{R}^{d_{model}}$ ，形成长度为 30 的序列 $\mathbf{Z}_0 = [T_{CLS}, T_1, \dots, T_{29}]$ 。[CLS] 自身不携带任何特征信息（随机初始化），但在经过多层自注意力后，它通过 Query 机制从所有特征令牌中聚合对分类最有用的信息。可以理解为：[CLS] 是模型学会的”最佳问题”，而每个特征令牌提供该特征的”回答”（Key-Value pair）。最终仅 [CLS] 的输出被送入分类头（LayerNorm $\rightarrow$ Linear(64 $\rightarrow$ 1) $\rightarrow$ Sigmoid）。

3.1.3 多头自注意力与 Transformer 编码器

这是 FT-Transformer 的核心计算引擎。给定输入序列 $\mathbf{Z}$ （ $S = 30$ 个令牌），单头自注意力执行：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Sparsemax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (2)$$

其中 $\mathbf{Q} = \mathbf{Z}\mathbf{W}_Q, \mathbf{K} = \mathbf{Z}\mathbf{W}_K, \mathbf{V} = \mathbf{Z}\mathbf{W}_V$ ， $d_k = d_{model}/n_{heads} = 8$ 。除以 $\sqrt{d_k}$ 防止内积过大导致梯度消失。多头设计使模型在 8 个不同的表示子空间中同时计算注意力，将各头输出拼接后经 $\mathbf{W}_O$ 投影回 d_{model} 维。

每个 Transformer 编码器层包含两个子层，各有残差连接和 Pre-Norm：

$$\begin{aligned} \mathbf{Z}' &= \text{LayerNorm}(\mathbf{Z} + \text{MultiHead}(\mathbf{Z})) \\ \mathbf{Z}'' &= \text{LayerNorm}(\mathbf{Z}' + \text{FFN}(\mathbf{Z}')) \end{aligned} \quad (3)$$

FFN 为两层结构，采用 ReGLU 激活 [3]： $\text{FFN}(\mathbf{x}) = (\text{ReLU}(\mathbf{x}\mathbf{W}_g + \mathbf{b}_g) \odot (\mathbf{x}\mathbf{W}_v + \mathbf{b}_v))\mathbf{W}_2 + \mathbf{b}_2$ ，中间维度 $d_{ffn} = 256$ 。残差连接确保即使注意力学不到有用信息，梯度仍能通过恒等路径回传。

本文配置为： $d_{model} = 64, n_{heads} = 8, n_{layers} = 3, d_{ffn} = 256$ ，总参数量 203,841。

3.2 Softmax 与 Sparsemax：两种归一化的数学性质对比

注意力归一化函数的选择在本文中占据核心位置。以下从数学性质和信息编码能力两个维度对比 Softmax 与 Sparsemax。

3.2.1 Softmax 的信息论属性

Softmax 将 logits 向量 $\mathbf{z} \in \mathbb{R}^d$ 映射为概率分布：

$$\text{Softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^d e^{z_j}} \quad (4)$$

Softmax 可被理解为求解以下优化问题的解：在约束 $\sum_i p_i = 1, p_i \geq 0$ 下，最大化熵 $H(\mathbf{p}) = -\sum_i p_i \log p_i$ 加上与 $\mathbf{z}$ 的内积 $\langle \mathbf{p}, \mathbf{z} \rangle$ 。从信息论角度看，Softmax 在”匹配 logits”与”保持最大熵”之间寻求平衡。这一性质在语义空间中有其合理性：当模型不确定哪两个 token 更相关时，保留一定概率质量给所有候选是一种审慎策略。

然而，最大熵倾向也意味着 Softmax **永远不能输出零概率**——因为 $e^{z_i} > 0$ 恒成立，即使 z_i 极低，其对应的 p_i 仍为正数。当所有 logits 值接近时（如本文情境中 Query-Key 内积高度同质化），Softmax 输出将退化为接近均匀分布 $\mathbf{p} \approx [1/d, \dots, 1/d]$ 。这一特性在需要明确特征取舍的场景中构成系统性缺陷。

3.2.2 Sparsemax 的闭式解与稀疏性

Sparsemax[8] 采用欧氏投影到概率单纯形，而非信息论投影：

$$\text{Sparsemax}(\mathbf{z}) = \arg \min_{\mathbf{p} \in \Delta^{d-1}} \|\mathbf{p} - \mathbf{z}\|_2^2 \quad (5)$$

其闭式解为：

$$\text{Sparsemax}(\mathbf{z})_i = \max(z_i - \tau(\mathbf{z}), 0) \quad (6)$$

其中 $\tau(\mathbf{z})$ 是唯一满足 $\sum_i \max(z_i - \tau, 0) = 1$ 的阈值。算法复杂度为 $O(d \log d)$ ——对 logits 降序排序，找到满足 $1 + kz_{(k)} > \sum_{j \leq k} z_{(j)}$ 的最大 k ，计算 $\tau = (\sum_{j \in S} z_{(j)} - 1)/k$ 。

Sparsemax 与 Softmax 的关键区别在于**边界解**：当 logits 值低于阈值 τ 时，Sparsemax 输出精确零——该特征被完全排除在注意力聚集之外。这一性质在表格数据上具有直接的操作意义：使模型能够明确区分“值得关注的特征”和“应忽略的特征”。

需要指出，Sparsemax 的稀疏化效应与其隐式的熵调节效应在本文实验中未分离。Softmax+ 温度缩放（temperature scaling）可能通过不同机制实现部分类似的校准改善，这一替代路径留待未来验证。

3.3 自注意力的信息论视角

上述架构描述提供了一个可操作的机制理解。但理解注意力塌缩还需要一个更深层的概念框架：自注意力本质上是在做什么？

从信息论角度，自注意力中的 Query-Key 内积 $\langle \mathbf{q}_i, \mathbf{k}_j \rangle$ 可被视为特征 i 与特征 j 之间**互信息**（mutual information）的代理变量。在 NLP 中，一个词的 Query 向量编码了“我在寻找什么类型的上下文信息”，而另一个词的 Key 向量编码了“我能提供什么类型的信息”——当两者匹配时，内积较大，注意力权重较高，信息从特征 j 流向特征 i 。

这一机制有效运行的前提是：**嵌入空间中的向量方向能够可靠地编码输入变量的“信息类型”身份**。当特征具有明确的语义身份时（如文本中的词性、图像中的空间位置），嵌入层可以通过学习将不同身份映射到不同方向，使得 Query-Key 内积产生有意义的差异。然而，当特征的身份是纯粹的数值索引（如 PCA 成分的序号），且特征的数值分布高度同构时，嵌入层将面临一个根本性困难：它需要从几乎相同的输入分布中学习出截然不同的嵌入方向——而梯度信号本身无法提供足够的区分性压力（因为所有特征的数值模式相似，对损失函数的梯度贡献也相似）。

这一分析表明，FT-Transformer 在 PCA 匿名化空间中的注意力困难不是参数数量不足的问题，而是**输入表征的信息结构不足以支撑注意力机制的前提假设**的问题。本文将这一困难称为嵌入空间的“语义真空”（semantic vacuum）。

3.4 注意力塌缩的形式化定义

基于以上分析，本文给出注意力塌缩的严格定义，为第6节的实证诊断建立基准。

定义 1 (注意力塌缩, Attention Collapse): 设 $\mathbf{A} \in \mathbb{R}^{d \times d}$ 为自注意力权重矩阵, 其中 $\mathbf{A}_{ij}$ 为特征 i 对特征 j 的注意力权重 (满足 $\sum_j \mathbf{A}_{ij} = 1$)。若存在 $\epsilon > 0$ 使得对所有 i, j 有:

$$|\mathbf{A}_{ij} - \frac{1}{d}| \leq \epsilon \quad (7)$$

且 $\epsilon \ll 1/d$ (即 $\epsilon/(1/d) \rightarrow 0$), 则称注意力发生了 ϵ -塌缩。其操作性判据为:

- 权重标准差 $\sigma(\{\mathbf{A}_{ij}\}) \ll 1/d$,
- 注意力分布 $\mathbf{A}$ 与均匀分布 $\mathcal{U} = [1/d, \dots, 1/d]$ 的 Jensen-Shannon 散度 $D_{JS}(\mathbf{A} \parallel \mathcal{U}) \approx 0$ 。

在本文的实验设置中 ($d = 29$ 个特征), 均匀基线为 $1/29 \approx 0.0345$ 。Softmax FTT 的实测注意力权重全部落在 $[0.0327, 0.0342]$ 区间内, 标准差 $\sigma = 0.0004 \ll 0.0345$, 满足 ϵ -塌缩条件。

重要的是, 注意力塌缩并不意味着 Attention 层“什么都不做”——塌缩的注意力矩阵等价于一个**均值池化**操作: $\sum_j (1/d) \mathbf{v}_j = \text{mean}(\mathbf{V})$ 。模型仍然可以基于均值池化后的聚合特征进行分类, 但丧失了自注意力的核心价值——根据特征间的条件关系进行有区分的特征加权。

3.5 LOR-MIM: 数据端对称破缺

第5节和第6节将评估一种从数据端打破 PCA 对称性的方法——局部正交松弛 (Local Orthogonality Relaxation via Mutual Information-gated Mixup, LOR-MIM)。该方法不修改 FT-Transformer 的架构, 而是在特征输入之前施加样本自适应的线性混合, 使 PCA 的全局正交结构在局部被松弛。

3.5.1 动机

PCA 强制 28 个 V 特征全局正交, 使它们在数值上完全对称。LOR-MIM 的核心假设是:**任何形式的非均匀结构——即使来自随机扰动——都能为后续的自我注意力提供可区分的特征交互基础**。这一假设受 mixup[9] 和 Manifold Mixup[10] 的启发——后者通过隐层插值为深度网络提供正则化, 而 LOR-MIM 将“插值”概念迁移至特征输入层, 以打破 PCA 对称性。额度 (Amount) 作为数据中唯一保留原始语义的特征, 被用作条件变量的自然选择。

3.5.2 方法

LOR-MIM 包含三个阶段: 离线分组 (训练前执行一次)、在线门控混合 (每笔交易执行)、端到端训练。

阶段一: MI 驱动的特征分组 (离线)。

1. **计算互信息**。对每个 V_j , 与 Amount 各自离散化为 20 个等宽箱, 统计 20×20 联合频列表 [11]:

$$\text{MI}(V_j; \text{Amount}) = \sum_a \sum_v P(v, a) \cdot \log \frac{P(v, a)}{P(v) \cdot P(a)}$$

共得 28 个标量 MI 值 [12]。实测范围 0.0015–0.0020——所有 V 特征与 Amount 的关系几乎相同。

2. **构建亲和矩阵**。将 MI 值归一化至 $[0, 1]$, 构造 $\mathbf{A}_{ij} = 1 - |\text{MI}_i - \text{MI}_j| \in \mathbb{R}^{28 \times 28}$ 。MI 值越接近 $\rightarrow$ 亲和度越高 $\rightarrow A_{ij}$ 越接近 1。
3. **谱聚类**。构建 $\mathbf{L} = \mathbf{D} - \mathbf{A}$ ($\mathbf{D}_{ii} = \sum_j A_{ij}$), 取 $\mathbf{L}$ 最小的 4 个非零特征向量作为 V 特征的嵌入坐标, 执行 K-means ($K=5$) [13]。输出 $\mathcal{G} = \{G_1, \dots, G_5\}$ ($[9, 8, 5, 3, 3]$)。

阶段二: 门控混合 (在线, 逐样本)。

4. **门控**。采用条件计算范式 [14], 小型 MLP 以标准化 Amount 为输入 ($1 \rightarrow 16 \rightarrow 5$, ReLU, Softmax), 输出组权重 $\alpha = [\alpha_1, \dots, \alpha_5]$, $\sum \alpha_k = 1$ 。

5. **组内混合**。每组 k 一个可学习矩阵 $M_k \in \mathbb{R}^{d_k \times d_k}$ (初始化为 $I + \mathcal{N}(0, 0.05)$)，变换为 $\mathbf{v}'_{G_k} = M_k \cdot \mathbf{v}_{G_k}$ ，乘以 α_k 后拼接各组结果，还原 V1-V28 原始顺序。Amount 不变。

6. **送入 FT-Transformer**。变换后的 $[\mathbf{v}', \text{Amount}]$ 输入标准 FT-Transformer。

阶段三：端到端训练。LOR-MIM 的 305 个参数与 FT-Transformer 联合优化——梯度从 Focal Loss 经 Transformer 回传至 M_k 和门控 MLP。算法3.5.2总结完整流程。

算法 1：LOR-MIM 完整流程

```
// 阶段一：离线分组（训练前，执行一次）
1. 对  $V_1$  至  $V_{28}$ ：计算与 Amount 的互信息（各离散化为 20 箱）
2. 归一化 28 个 MI 值  $\rightarrow$  构建亲和矩阵  $\mathbf{A}_{ij} = 1 - |\text{MI}_i - \text{MI}_j|$ 
3.  $\mathbf{L} \leftarrow \mathbf{D} - \mathbf{A}$ ，取  $\mathbf{L}$  最小的 4 个非零特征向量构成嵌入坐标
4. 在嵌入坐标上 K-means ( $K=5$ )  $\rightarrow$  分组  $\mathcal{G} = \{G_1, \dots, G_5\}$ 
// 阶段二：在线变换（每笔交易）
5.  $\alpha \leftarrow \text{Softmax}(\text{MLP}(\text{Amount}))$  // 门控 (1 $\rightarrow$ 16 $\rightarrow$ 5)
6. 对每组  $k$ ： $\mathbf{v}'_{G_k} \leftarrow \alpha_k \cdot (M_k \cdot \mathbf{v}_{G_k})$  //  $M_k$  可学习
7. 拼接各组，还原 V1-V28 顺序，拼接 Amount  $\rightarrow$  29 维向量
// 阶段三：训练
8. 变换向量送入 FT-Transformer，Focal Loss 端到端联合优化
额外参数：305 个 (0.15%)   关键约束： $M_k$  初始化为  $I + \mathcal{N}(0, 0.05)$ 
```

需要指出，阶段一的 MI 实测值极低 (0.0015–0.0020)，亲和矩阵近乎全 1，谱聚类分组与随机分组差异有限。然而第6节的实验将表明，即使是近似随机的分组也能有效打破对称——对称破缺对分组精度的要求极低。

4 实验设置

本章描述实验的技术配置。数据来源、EDA 和预处理流程见第2节。

4.1 损失函数选择：Focal Loss 的必要性

数据集欺诈率仅 0.5%（正负比约 1:200），标准的二元交叉熵（BCE）在此极度不平衡条件下存在严重缺陷：正常交易样本占总样本的 99.5%，BCE 的梯度将被多数类主导，模型在训练早期就会收敛到“预测所有样本为正常”的退化解。

Focal Loss[15] 通过两个机制解决这一问题：

$$\text{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (8)$$

其中 $p_t = p$ 当 $y = 1$ 否则 $p_t = 1 - p$ ， $\alpha_t = \alpha$ 当 $y = 1$ 否则 $\alpha_t = 1 - \alpha$ 。

- **聚焦参数** $\gamma = 2.0$ ：降低易分类样本的损失权重，使训练集中于难分类样本。
- **平衡参数** $\alpha = 0.25$ ：调节正负类权重。本文选择 $\alpha = 0.25$ ，因为 Sparsemax 已通过稀疏特征选择内置了一定的抗不平衡能力。

4.2 模型配置

本文通过四个控制变量实验构建诊断链，所有变体的架构基础完全一致（表1）：

表 1: 四个实验变体及控制变量。所有变体共享相同的 FT-Transformer 架构（手写实现，ReGLU，203,841 参数），损失函数统一为 Focal Loss，LOR-MIM 变体额外增加 305 参数 (0.15%)。

变体	注意力归一化	数据预处理
Softmax 基线	Softmax	无
Sparsemax	Sparsemax	无
LOR-MIM + Softmax	Softmax	LOR-MIM 混合
LOR-MIM + Sparsemax	Sparsemax	LOR-MIM 混合

共享的架构配置： $d_{model} = 64$, $n_{heads} = 8$, $n_{layers} = 3$, $d_{ffn} = 256$ ，总参数量 203,841。

4.3 LOR-MIM 配置

LOR-MIM 的具体原理见第3节。其关键超参配置如下：

- **分组数 $K = 5$** : 基于 V 特征与 Amount 的互信息经谱聚类将 28 个 V 特征分为 5 组（分组结果：[9, 8, 5, 3, 3]）。
- **门控 MLP**: 单隐藏层（ $1 \rightarrow 16 \rightarrow 5$ ，ReLU 激活，Softmax 归一化），以标准化的 Amount 为唯一输入。
- **混合矩阵**: 每组一个 $d_k \times d_k$ 矩阵 M_k ，初始化为 $I + \mathcal{N}(0, 0.05)$ （近单位阵 + 小高斯噪声）。
- **参数量**: 305 个额外参数（门控 MLP 293 + 混合矩阵 12 组），占 FT-Transformer 总参数的 0.15%。

4.4 训练策略

所有变体使用完全一致的训练配置：AdamW 优化器（ $lr=1 \times 10^{-3}$ ，weight_decay = 10^{-5} ， $\beta_1=0.9$ ， $\beta_2=0.999$ ），批量大小 512，最大训练轮数 100，早停 patience=15（基于验证集 AUPRC），梯度裁剪 max_norm=1.0，ReduceLROnPlateau 学习率调度（patience=8，factor=0.5）。每个模型训练前显式重置 random、numpy、torch 和 cuda 的全部随机状态（统一 seed=42）以确保可复现性。所有实验在 NVIDIA GeForce RTX 4060 (8GB) GPU 和 PyTorch 2.11.0+cu128 环境下完成。

4.5 评估指标

- **AUPRC**（主要指标）: 聚焦正类（欺诈）的排序能力。在不平衡数据上，ROC-AUC 的区分度远低于 AUPRC[16]。
- **AttnStd**（注意力权重标准差）: 塌缩程度的直接度量。均匀基线 $1/29 \approx 0.0345$ 。
- **ECE**（Expected Calibration Error）: 概率校准质量。将预测概率等分为 10 个分位区间，计算各区间内平均预测概率与平均真实正类率之差的加权平均。ECE 越低表示模型的概率估计越可信——这对风控业务至关重要：过度自信的模型会产生误导性高风险预警。
- **F1-Score、Precision、Recall**: 在验证集 F1 最大化的最优阈值处计算。
- **Cost**: 业务成本 = $FP \times 1 + FN \times 10$ （漏报权重 10 倍于误报）。

5 实验结果

本章从性能、注意力分布和曲线分析三个层面，呈现四个变体的对照实验结果。本章仅描述“观察到了什么”——深层机制解释留待第6节展开。所有变体均使用 Focal Loss 处理类别不平衡（欺诈率 0.5%），差异仅来自注意力归一化函数和数据预处理层。

5.1 整体性能对比

表2汇总了四个变体的定量指标。除 AUPRC 和 F1 外，引入两个补充维度：AttnStd 衡量注意力塌缩程度，ECE 衡量概率校准质量。

表 2: 五个 FTT 变体的性能对比。架构（手写，ReGLU, 203,841 参数）完全一致，LOR-MIM 变体额外增加 305 参数。加粗为各列最优值。

模型	AUPRC	F1	AttnStd	Cost	ECE
Softmax	0.9126	0.9266	0.00125	115	0.2328
Sparsemax	0.9384	0.9279	0.00942	97	0.0120
LOR-MIM + Softmax	0.9242	0.9358	0.01401	104	0.0068
LOR-MIM + Sparsemax	0.9267	0.9140	0.02064	118	0.0066

表2揭示了一个关键现象：**没有任何模型在所有指标上全面占优**。最优 AUPRC 属于 BCE (0.9491)，最优 F1 属于 LOR-MIM+Softmax(0.9358)，最低业务成本属于 Sparsemax(Cost=97)，最优校准同样属于 BCE (ECE=0.0001，近乎完美)。这一“多指标最优解互不兼容”的模式意味着：在 PCA 匿名化数据上，排序精度 (AUPRC)、硬分类质量 (F1)、业务成本 (Cost) 和概率可靠性 (ECE) 之间存在着需要业务方根据具体风险偏好进行权衡的内在张力。

值得注意的几组数据：(1) Softmax 的 ECE 高达 0.2328——模型对预测概率严重过度自信，这在实际风控中意味着“该交易 90% 概率是欺诈”的声明实际上对应的真实欺诈概率远低于 90%；(2) Sparsemax 将 ECE 改善至 0.0120 (~20 倍)，其零截断阻断了低质量权重在多层的噪声累积；(3) BCE 不仅 AUPRC 最高，ECE 也几乎完美 (0.0001)——无 Focal Loss 的梯度集中效应，模型在概率校准上反而受益；(4) LOR-MIM 的两个变体 ECE 均在 0.007 以下，说明数据端对称破缺也附带了校准改善的副产物。BCE 的 F1 (0.9278) 和 Cost (103) 未超越 Sparsemax，表明其优势集中在排序和校准层面。

5.2 注意力权重分布：塌缩与修复

图4以 2×2 网格展示了四个代表性变体的注意力权重分布。

注意到 LOR-MIM 的两个变体中注意力分布的标准差最大，但零权重特征很少——LOR-MIM 通过组内混合使注意力在更多特征上分配非零权重，而非像 Sparsemax 那样通过截断来集中权重。这与表2中 LOR-MIM+Softmax F1 最高但 AUPRC 并非最优的模式一致：更分散的注意力有利于硬分类 (F1)，但不一定有利于排序 (AUPRC)。

5.3 多头注意力的同质化

Softmax 基线中任意两个注意力头余弦相似度 >0.97——8 个头功能上近乎等价。Sparsemax 替换后降至约 0.88，LOR-MIM 变体进一步降至约 0.82。多头设计的互补目标在 PCA 空间中基本未能实现。

5.4 PR 曲线与 ROC 曲线

Precision-Recall 曲线和 ROC 曲线从不同角度衡量模型的排序性能。在不平衡数据上，两者的区分能力存在根本性差异：ROC-AUC 以真负类率 (TNR) 为横轴，而真负类占样本的 99.5%，使得不同模型在该轴上几乎无法区分；PR 曲线以 Recall 为横轴、Precision 为纵轴，两者均聚焦于正类（欺诈），对模型间的排序差异更为敏感 [16]。图5将四个变体的两条曲线并列呈现，这一并置本身就是对评估指标选择的方法论说明。

PR 曲线中，Sparsemax 在整个召回区间（尤其是 0.3–0.8）系统性地高于 Softmax 基线和两个 LOR-MIM 变体，这与表2中 Sparsemax AUPRC 最优 (0.9384) 一致。值得注意的是 LOR-MIM+Sparsemax（绿色）在低召回区 (<0.2) 的精确率略高于 Sparsemax，但在中高召回区被反超——这表明数据端修复在保守决策区（低召回 = 只标记最确信的欺诈）可能有一





图 4: 四个 FTT 变体的注意力权重分布 ($n=200$)。Softmax 基线塌缩为均匀分布 ($\text{std}=0.00125$)；Sparsemax 部分恢复稀疏性 ($\text{std}=0.00942$)；LOR-MIM+Softmax 实现大幅多样性恢复 ($\text{std}=0.01401$)；LOR-MIM+Sparsemax 多样性最高 ($\text{std}=0.02064$)。

定优势，但在需要覆盖更多欺诈交易的场景下不如纯归一化修复。两个 LOR-MIM 变体的 PR 曲线几乎重叠，进一步确认了 LOR-MIM 与 Sparsemax 联合使用时存在拮抗效应：组合并未产生相加增益。

ROC 曲线中，四个变体几乎完全重叠——AUC 极差不足 0.005。若仅报告 ROC-AUC，不仅 Sparsemax 的 +2.6pp 改善被完全掩盖，LOR-MIM 变体之间的细微差异也无法分辨。这一对比直接验证了本文以 AUPRC 作为主评估指标的合理性。



(a) Precision-Recall 曲线

(b) ROC 曲线

图 5: 四个变体的排序性能曲线。(a) PR 曲线：Sparsemax 领先。(b) ROC 曲线：所有变体近乎重叠。

5.5 置换特征重要性

置换重要性分析 (图6) 对比了 Softmax、Sparsemax 和 LOR-MIM+Softmax 三个变体的特征依赖性。三者特征排序高度一致 (两两 Pearson $r > 0.9$)，V14 均为首要特征但占比均

<15%。无论使用何种注意力归一化或是否加入 LOR-MIM，模型在 PCA 空间中均呈分布式特征利用模式——这与塌缩诊断一致：当嵌入方向高度同构时，模型无法对单一特征形成集中依赖。




图 6: 三个 FTT 变体的置换特征重要性。三者排序高度一致 ($r > 0.9$)，V14 为首要特征但占比均未超过 15%。

6 诊断：塌缩的深层机制

第5节的实验结果确立了四个实证事实：(1) Softmax 注意力塌缩为均匀分布；(2) 8 个注意力头全部同质化；(3) Sparsemax 和 LOR-MIM 分别从不同路径改善了塌缩；(4) 注意力多样性与分类性能之间不存在简单的线性关系。本章从嵌入空间结构、损失函数效应和“症状 vs 病因”三个维度，探究这些事实背后的深层机制。

6.1 嵌入空间的结构证据

塌缩的直接原因是 Query-Key 内积对所有特征对产生近乎相同的值。但其深层原因在更上游——为什么 Query 和 Key 向量本身缺乏区分度？

对 FTT+Softmax 模型训练后的 Feature Tokenizer 嵌入权重矩阵 $\mathbf{W} \in \mathbb{R}^{29 \times 64}$ 进行奇异值分解 (SVD)：第一个奇异值主导了总方差的 73.1%，前三个奇异值合占 88.6%。这意味着 29 个特征专属的 64 维嵌入向量几乎全部位于由仅仅 3-4 个主方向张成的低维子空间中——嵌入层的有效秩远低于其名义维度。

进一步分析任意两个特征嵌入向量 $\mathbf{W}_i$ 与 $\mathbf{W}_j$ 的内积分布：所有 $29 \times 28/2 = 406$ 对特征嵌入之间的内积均偏正，且方差极小——没有任何一对特征的嵌入指向相反或正交的方向。在正常的语义嵌入空间中（如词嵌入），“语义相反”或“语义无关”的词对应嵌入向量应呈负内积或近零内积。但在 PCA 特征空间中，所有嵌入向量指向同一象限——Feature Tokenizer 未能通过训练学习到任何“对抗性”的方向差异。

这一嵌入同构性并非特定于本数据集的偶然现象，而是 PCA 匿名化特征空间的系统性后果：所有 V1-V28 是同一组主成分的不同线性组合，它们的数值分布相似（标准化后的标准正态），它们的“身份”仅由在主成分空间中的坐标位置区分。Feature Tokenizer 面临的任务——从几乎相同的输入分布中学习出截然不同的嵌入方向——在梯度信号层面缺乏足够的区分性压力：所有 29 个特征对损失函数的梯度贡献是近乎对称的。

置换重要性分析（第5节图6）从另一角度佐证了这一诊断。Softmax、Sparsemax 和 LOR-MIM+Softmax 三个变体的特征排序高度一致（两两 Pearson $r > 0.9$ ），V14 虽为首要特征，但其置换效应占比均未超过 15%——即使在特征被随机打乱后，模型性能的下落分散在多个特征上，而非集中于少数关键特征。这种分布式的特征依赖性模式与注意力塌缩的诊断一致：当所有特征嵌入方向趋同时，模型无法形成对单个特征的集中依赖。

综合嵌入 SVD 分析 (第6.1节), 塌缩的根因判定为 PCA 空间中特征嵌入的方向同构性。所有 V1-V28 是同一组主成分的不同线性组合, Feature Tokenizer 从几乎相同的输入分布中学习嵌入方向, 梯度信号缺乏区分性压力。置换重要性分析中三个变体高度一致的分布式特征依赖模式 (第5节图6) 进一步佐证了这一诊断。

6.2 Sparsemax 修复的精确定界：症状而非病因

综合上述诊断, Sparsemax 的 +2.6pp AUPRC 改善 (0.9126→0.9384) 可被分解为两个独立效应的叠加:

1. **归一化改善 (症状修复)**: Softmax 的 $e^{z_i} > 0$ 恒成立特性使其在任何输入上都输出全非零分布——当 Query-Key 内积高度集中时, 输出被迫趋近均匀。Sparsemax 将此替换为欧氏投影的截断规则: 低于阈值 τ 的特征被直接赋予零权重。这一替换的效果是解放性的——它让注意力机制摆脱了 Softmax 在低差异输入上的”强制均匀化”锁死。AUPRC 因此从 0.9126 跃升至 0.9384。
2. **噪声阻断 (校准改善)**: Softmax 的微量非零权重在多层的残差累积中被放大——即使单层注意力中 1% 的差异权重, 在 3 层 Transformer 的残差连接中通过逐层累积可能放大至显著水平——最终传导至分类头产生过度自信的预测 (ECE=0.2328)。Sparsemax 的零截断阻断了这一”噪声累积 → 过度自信”的传导链 (ECE 降至 0.0120)。

然而, Sparsemax 修复的是塌缩的**症状** (Softmax 饱和导致的强制均匀化), 而非**病因** (Feature Tokenizer 的嵌入方向缺乏鉴别力)。它允许注意力机制”自由地”在不同特征上分配权重, 但没有提供关于**哪些特征应该被分配更多权重**的信息。如果 Feature Tokenizer 的嵌入空间中所有特征确实难以区分, Sparsemax 的”选择”将退化为基于微小随机差异的任意截断, 而非基于语义相关的精准筛选。

这一”症状-病因”的区分解释了为什么 Sparsemax 后的注意力分布虽然有所改善 (不再所有特征均分), 但仍然缺乏精准的鉴别性: **Sparsemax 修复了注意力权重的表达自由度, 但无法替代 Feature Tokenizer 为嵌入空间注入区分的语义差异。**

6.3 LOR-MIM 修复的精确定界：数据端对称破缺及其与 Sparsemax 的拮抗

LOR-MIM 代表第二条修复路径——从数据端打破 PCA 的全局对称。其原理已在第3节详细介绍, 此处聚焦于实验结果对诊断框架的意义。

LOR-MIM+Softmax 的结果 (AUPRC=0.9242, AttnStd=0.01401) 确立了第一条结论: **打破 PCA 对称确实能让注意力”活过来”——注意力多样性在所有方法中最高 (×11.2)**。但 AUPRC 改善 (+1.2pp) 远小于 Sparsemax (+2.6pp), 说明病因端的修复并不能自动转化为分类性能的改善。

6.3.1 与 Sparsemax 联合使用的拮抗效应

更具诊断价值的是 LOR-MIM+Sparsemax 联合实验 (AUPRC=0.9267, AttnStd=0.02064): 注意力多样性被推至 ×16.5, 但 AUPRC **反低于** Sparsemax 单独使用 (0.9384)。

这一反直觉的结果揭示了两条修复路径之间的**结构性拮抗**:

1. **Sparsemax 的机制依赖 logits 的序关系**: Sparsemax 通过截断低于阈值 τ 的 logits 来实现稀疏选择——它选择的是 Query-Key 内积在原始特征空间中”相对更大”的特征。这一序关系即使在全塌缩的均匀分布中也微弱存在 (否则 Sparsemax 将完全随机选择)。
2. **LOR-MIM 的混合打乱了这一序关系**: 组内线性混合使特征的 logits 值发生系统性重排——原来”稍高”的特征可能在混合后变成”稍低”, 反之亦然。对于 Sparsemax 而言, 这相当于将微弱的信号替换为噪声。
3. **拮抗的实质**: LOR-MIM 为注意力提供了更多”可区分的差异”, 但这些差异的排序结构是随机的——Sparsemax 据此做出的稀疏选择因此偏离了数据中的真实判别性结构, 导致分类性能反降。

6.3.2 两条修复路径的互补定位与边界

综合四模型结果，两条修复路径的精确边界可被界定为：

- **归一化端 (Sparsemax)**：解锁注意力权重自由度，依赖数据中残余的微弱序关系进行稀疏选择。优势在于 $\times 7.5$ 多样性 + AUPRC 0.9384 + ECE 0.0120；弱点在于不能提升嵌入层的方向鉴别力。
- **数据端 (LOR-MIM)**：在特征层面打破 PCA 对称，制造可区分的 token 交互。优势在于多样性恢复最强 ($\times 11.2-16.5$)，且可与任何模型架构组合；弱点在于引入的结构不保证与分类相关，且与 Sparsemax 稀疏选择机制拮抗。

这一分析揭示了论文最核心的诊断发现：**在 PCA 匿名化空间中，注意力多样性与分类性能是两个相关但不线性的维度；两条修复路径各自提升其中一个维度，但路径之间存在结构性拮抗，联合使用反而可能削弱整体效果。**

6.4 塌缩的诊断框架

基于上述诊断，本文归纳了一个描述性的三阶段诊断模板，用于在其他数据集上检验自注意力是否发生了类似塌缩：

1. **第一阶段（注意力分布检验）**：检查注意力权重分布的标准化标准差 $\sigma/(1/d)$ ——若该值 < 0.05 （即标准差不足均匀基线的 5%），则塌缩高度可能。
2. **第二阶段（嵌入结构检验）**：对 Feature Tokenizer 的嵌入权重矩阵进行 SVD——若前 3 个奇异值占比 $> 80\%$ ，则嵌入空间有效秩不足。
3. **第三阶段（修复路径交互检验）**：若多种修复路径可用，检验其联合使用时的协同或拮抗关系——LOR-MIM 与 Sparsemax 的拮抗效应表明，独立有效的修复路径在联合时可能产生负交互。

需要强调的是，该框架在本文中仅在一个数据集上演示，应被视为**提出的诊断模板**而非已验证的通用框架。此外，LOR-MIM 的实验结果暗示了一个潜在的第四阶段——**修复路径交互检验**：若多种修复路径同时可用，检验它们之间的协同或拮抗关系，可进一步揭示塌缩的机制结构。LOR-MIM+Sparsemax 的拮抗效应表明，前三阶段的“归因—修复”逻辑在路径交叉时可能不成立——这也是未来工作中最值得深入的方向。

从金融机构的实践角度，上述诊断框架给出了一个简洁的操作建议：当数据必须经过匿名化处理时，（1）优先使用树模型或不依赖注意力的 MLP 架构；（2）若业务需求要求使用 Transformer 类模型，至少应将 Softmax 替换为 Sparsemax（零成本、一行代码、AUPRC +2.6pp）；（3）将注意力分布标准差 $\sigma/(1/d)$ 纳入模型上线前的例行质量检查——塌缩的注意力意味着模型无法为风控决策提供任何有意义的特征归因。

7 结论

本文以 FT-Transformer 为载体，对自注意力机制在 PCA 匿名化表格数据上的失效模式进行了系统诊断。通过四个变体的对照实验，考察了两条修复路径的精确边界及其交互效应。全文凝练为三个递进的结论。

7.1 结论一：PCA 空间是注意力塌缩的根因

嵌入 SVD 分析表明，29 个特征专属的 64 维嵌入向量几乎全部位于 3-4 个主方向张成的低维子空间中，有效秩远低于名义维度。PCA 匿名化使所有 V 特征的数学属性高度同构——它们的数值分布相似，“身份”仅由在主成分空间中的坐标位置区分。Feature Tokenizer 从几乎相同的输入分布中学习截然不同的嵌入方向，面临梯度层面的区分性困难。这一结构性前提使自注意力在 PCA 匿名化数据上系统性失效——无论后续如何修复归一化函数，嵌入层都缺乏为注意力提供方向鉴别力的能力。

7.2 结论二：两条修复路径各有边界，联合使用存在结构性拮抗

归一化端 (Sparsemax) 恢复注意力多样性 $\times 7.5$, AUPRC 提升至 0.9384 (+2.6pp), ECE 改善至 0.0120 (~ 20 倍), 但修复的是 Softmax 饱和的”症状”而非嵌入同构的”病因”。数据端 (LOR-MIM) 通过门控混合打破 PCA 对称, 实现最大多样性恢复 ($\times 11.2\text{--}16.5$), 但 AUPRC 改善有限 (+1.2pp), 且与 Sparsemax 联合使用时产生拮抗效应——LOR-MIM+Sparsemax 的注意力多样性达 $\times 16.5$ 但 AUPRC 仅为 0.9267, 低于 Sparsemax 单独使用的 0.9384。LOR-MIM 的混合破坏了 Sparsemax 稀疏选择所依赖的 logits 序关系: 数据端修复让注意力”活过来”, 但归一化端修复的”选择”因此偏离方向。

这一拮抗效应构成了本文最核心的科学发现: 在 PCA 空间中, ”注意力能不能区分特征”和”注意力区分得对不对”是两个相互独立且可能冲突的维度。两条修复路径各自提升其中一个维度, 但无法同时兼顾两者——这正是未来工作的明确方向。

7.3 结论三：诊断优于比较

本文隐含的方法论立场是: 系统**诊断**失效模式比**比较**性能数字提供更多可迁移的知识。四个变体的 AUPRC 数值无法揭示拮抗关系——是 LOR-MIM+Sparsemax 联合实验的设计, 将两条修复路径从”独立有效”重新框定为”相互拮抗”。如果论文的核心叙事是”方法 A 优于方法 B”, 其结论受限于数据集; 如果是”方法 A 与 B 在机制 X 上拮抗”, 其结论是可迁移的。

7.4 对金融行业的实践启示

本文的诊断发现对金融机构的模型选型具有直接的操作指导意义:

1. **在使用 PCA 匿名化数据时, 优先验证注意力塌缩风险。**建议金融机构在使用 Transformer 类模型处理匿名化表格数据前, 先执行本文提出的注意力分布检验 (计算 $\sigma/(1/d)$ 比值)——若该值低于 0.05, 塌缩风险较高, 需考虑替代方案。
2. **根据数据匿名化程度选择模型架构。**数据经 PCA 匿名化且无任何语义锚点时, Sparsemax 替代 Softmax 是一个低成本的改善方案 (AUPRC +2.6pp, 改一行代码)。若业务允许接受 BCE 在不平衡场景下的理论风险, 在本实验条件下 BCE 训练提供了最高的排序精度 (AUPRC 0.9491)。LOR-MIM 适合作为”附加诊断层”——将其加入 pipeline 后注意力多样性的大幅提升可作为模型是否对特征结构敏感的检验信号。
3. **将注意力多样性指标纳入风控模型上线前的质量检查清单。**塌缩的注意力意味着模型无法解释”为什么这笔交易被判定为欺诈”——在面临监管审查时, 均匀的注意力分布无法提供任何特征归因信息。定期监测注意力分布, 可在模型性能尚未出现显著下降之前发现特征匿名化带来的结构性退化。

局限与未来工作。本文的局限——单数据集、单种子 (seed=42)、诊断框架的外部验证缺失——已在正文中指出。PCA 匿名化场景比表面看起来更普遍: 联邦学习中的差分隐私梯度扰动、多传感器阵列的同质测量、差分隐私表格数据发布中的随机投影, 都可能产生类似的”语义真空”效应。本文的发现和诊断框架在这些场景中的适用性, 构成未来研究的重要方向。

References

- [1] A. Vaswani et al., ”Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008.
- [2] A. Dosovitskiy et al., ”An image is worth 16x16 words: Transformers for image recognition at scale,” 2021.
- [3] Y. Gorishniy, I. Rubachev, V. Khrulkov, and A. Babenko, ”Revisiting deep learning models for tabular data,” in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 18 932–18 943.

- [4] L. Grinsztajn, E. Oyallon, and G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?” In *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 507–520.
- [5] V. Borisov, T. Leemann, K. Seßler, J. Haug, M. Pawelczyk, and G. Kasneci, “Deep neural networks and tabular data: A survey,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 6, pp. 7499–7519, 2024.
- [6] N. Elgiriye withana, *Credit card fraud detection dataset 2023*, 2023. DOI: 10.34740/KAGGLE/DSV/6492730 [Online]. Available: <https://www.kaggle.com/dsv/6492730>
- [7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2019, pp. 4171–4186.
- [8] A. F. T. Martins and R. F. Astudillo, “From softmax to sparsemax: A sparse model of attention and multi-label classification,” in *Proceedings of the 33rd International Conference on Machine Learning*, vol. 48, 2016, pp. 1614–1623.
- [9] H. Zhang, M. Cissé, Y. N. Dauphin, and D. Lopez-Paz, “Mixup: Beyond empirical risk minimization,” in *International Conference on Learning Representations*, 2018.
- [10] V. Verma et al., “Manifold mixup: Better representations by interpolating hidden states,” in *International Conference on Machine Learning*, 2019, pp. 6438–6447.
- [11] A. Kraskov, H. Stögbauer, and P. Grassberger, “Estimating mutual information,” *Physical Review E*, vol. 69, no. 6, p. 066 138, 2004.
- [12] H. Peng, F. Long, and C. Ding, “Feature selection based on mutual information: Criteria of max-dependency, max-relevance, and min-redundancy,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 27, no. 8, pp. 1226–1238, 2005.
- [13] A. Y. Ng, M. I. Jordan, and Y. Weiss, “On spectral clustering: Analysis and an algorithm,” *Advances in Neural Information Processing Systems*, vol. 14, pp. 849–856, 2001.
- [14] Y. Han, G. Huang, S. Song, L. Yang, H. Wang, and Y. Wang, “Dynamic neural networks: A survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 11, pp. 7436–7456, 2021.
- [15] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 2980–2988.
- [16] T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLoS ONE*, vol. 10, no. 3, e0118432, 2015.